University of Calabria, DIMES High Level Synthesis of Digital Systems 2023-2024

Prof.ssa PERRI Prof. FRUSTACI

Sparse Matrix Vector Multiplication Analysis

${\it Giorgio~Ubbriaco}\atop 247284\\ {\it bbrgrg}00h11d086x@studenti.unical.it}$

June 2024

Index

1	Introduction 1.1 Sparse Matrix	
2	Tasks to be performed	7
3	Definitions	8
4	C Simulations	ę
5	5.1 Solution 1 5.2 Solution 2 5.3 Solution 3 5.4 Solution 4 5.5 Solution 5 5.6 Solution 6 5.7 Solution 7 5.8 Solution 8 5.9 Solution 9 5.10 Solution 10	15 17 21 24 27 31 37 40 40
6	Conclusions	56

Listings

definitions/definitions.h		
c_simulations/smvmTB.cpp		9
$c_simulations/smvmTB_output.cpp \ . \ . \ . \ . \ . \ . \ . \ . \ . \$		10
c_simulations/stdm.cpp		
solutions/s1/s1.cpp		12
solutions/s1/s1tripcount.cpp		12
solutions/s2/s2.cpp		
solutions/s3/s3.cpp		
solutions/s3/s3modificata.cpp		
solutions/s4/s4.cpp		
solutions/s5/s5.cpp		
solutions/s6/s6all3.cpp		
solutions/s6/s6columnIndex.cpp		
solutions/s6/s6values.cpp		
solutions/s6/s6x.cpp	• •	28
solutions/s7/s7.cpp		
solutions/s7/s7columnIndex.cpp		
solutions/s7/s7values.cpp		
solutions/s7/s7x.cpp		
solutions/s7/s7loop1pipeline.cpp		
solutions/s8/s8all3.cpp		37
solutions/s8/s8columnIndex.cpp		
solutions/s8/s8values.cpp		
solutions/s8/s8x.cpp		
solutions/s9/s9.cpp		40
solutions/s9/s9columnIndex.cpp		
solutions/s9/s9values.cpp		41
solutions/s9/s9x.cpp		42
solutions/s9/s9rowPtr4.cpp		42
solutions/s9/s9y4.cpp		43
solutions/s9/s9pipelineloop1.cpp		44
solutions/s10/s10all3.cpp		46
solutions/s10/s10columnIndex.cpp		46
solutions/s10/s10values.cpp		46
solutions/s10/s10x.cpp		
solutions/s10/headermodified.h		
solutions/s10/s10all3modified.cpp		
m solutions/s10/s10columnIndexmodified.cpp		48
solutions/s10/s10valuesmodified.cpp	• •	48
solutions/s10/s10xmodified.cpp		48
solutions/s10/s10xinodined.cpp		52
solutions/s11/s11all3.cpp		$\frac{52}{52}$
		$\frac{52}{52}$
solutions/s11/s11columnIndex.cpp		
solutions/s11/s11values.cpp		53
solutions/s11/s11x.cpp		53
solutions/s11/headermodified.h		53
List of Figures		
1 HLS Solution 1 Analysis		13
2 HLS Loop Pipelining		15
3 HLS Solution 3 Analysis		18

4	HLS Loop Unrolling	21
5	HLS Solution 4 Analysis	22
6	HLS Solution 5 Analysis	25
7	HLS Array Partitioning	27
8	HLS Solution 10 Analysis	50
9	Latency measurements for different solutions	57
10	Utilization Export RTL Plot	59
List	of Tables	
1	SMVM Solutions To Be Performed	7
$\overset{-}{2}$	SMVM Solutions To Be Performed	11
3	HLS Solution 1 without Trip Count Timing Summary (ns)	12
4	HLS Solution 1 without Trip Count Latency Summary (clock cycles)	12
5	HLS Solution 1 without Trip Count Latency Summary (clock cycles)	12
6	HLS Solution 1 with Trip Count Timing Summary (ns)	13
7	HLS Solution 1 with Trip Count Latency Summary (clock cycles)	13
		13
8	HLS Solution 1 Latency with Trip Count Loops Summary	
9	HLS Solution 1 with Trip Count Utilization Estimates Summary	14
10	HLS Solution 1 with Trip Count C/RTL Cosimulation Summary	14
11	HLS Solution 1 with Trip Count Export RTL Resource Usage	14
12	HLS Solution 1 with Trip Count Export RTL Final Timing	14
13	HLS Solution 2 Timing Summary (ns)	15
14	HLS Solution 2 Latency Summary (clock cycles)	15
15	HLS Solution 2 Latency Loops Summary	15
16	HLS Solution 2 Utilization Estimates Summary	16
17	HLS Solution 1 with Trip Count C/RTL Cosimulation Summary	16
18	HLS Solution 2t Export RTL Resource Usage	16
19	HLS Solution 2 Export RTL Final Timing	16
20	HLS Solution 3 Timing Summary (ns)	17
21	HLS Solution 3 Latency Summary (clock cycles)	17
22	HLS Solution 3 Latency Loops Summary	17
23	HLS Solution 3 Utilization Estimates Summary	18
24	HLS Solution 1 with Trip Count C/RTL Cosimulation Summary	18
25	HLS Solution 2t Export RTL Resource Usage	19
26	HLS Solution 2 Export RTL Final Timing	19
27	HLS Solution 3 Modified Timing Summary (ns)	19
28	HLS Solution 3 Modified Latency Summary (clock cycles)	19
29	HLS Solution 3 Modified Latency Loops Summary	19
30	HLS Solution 3 Modified Utilization Estimates Summary	20
31	HLS Solution 4 Timing Summary (ns)	21
32	HLS Solution 4 Latency Summary (clock cycles)	21
33	HLS Solution 4 Latency Loops Summary	22
34	HLS Solution 4 Utilization Estimates Summary	22
35	HLS Solution 4 C/RTL Cosimulation Summary	23
36	HLS Solution 4 Export RTL Resource Usage	23
37	HLS Solution 4 Export RTL Final Timing	23
38	HLS Solution 5 Timing Summary (ns)	24
39	HLS Solution 5 Latency Summary (clock cycles)	24
40	HLS Solution 5 Latency Loops Summary	24
41	HLS Solution 5 Utilization Estimates Summary	25
42	HLS Solution 5 C/RTL Cosimulation Summary	25
43	HLS Solution 5 Export RTL Resource Usage	26
44	HLS Solution 5 Export RTL Final Timing	26

45	HLS Solution 6 Timing Summary (ns)	29
46	HLS Solution 6 Latency Summary (clock cycles)	29
47	HLS Solution 6 Latency Loops Summary	29
48	HLS Solution 6 Utilization Estimates [#]	29
49	HLS Solution 6 C/RTL Cosimulation Report	
50	HLS Solution 6 Export RTL Report	
51	HLS Solution 7 Timing Summary (ns)	
52	HLS Solution 7 Latency Summary (clock cycles)	
53	HLS Solution 7 Latency Loops Summary	
54	HLS Solution 7 with columnIndex partitioning Latency Loops Summary	32
55	HLS Solution 7 with columnIndex and values partitioning Latency Loops Summary	32
56	HLS Solution 7 with columnIndex, values and x partitioning Timing Summary (ns)	33
57	HLS Solution 7 with columnIndex, values and x partitioning Latency Summary (clock cycles)	33
58	HLS Solution 7 with columnIndex, values and x partitioning Latency Loops Summary	33
59	HLS Solution 7 with columnIndex, values and x partitioning Utilization Estimates Summary	34
60	HLS Solution 7 with columnIndex, values and x partitioning C/RTL Cosimulation Summary	34
61	HLS Solution 7 with columnIndex, values and x partitioning Export RTL Resource Usage	34
62	HLS Solution 7 with columnIndex, values and x partitioning Export RTL Final Timing	34
63	HLS Solution 7 with loop1 pipelined Timing Summary (ns)	35
64	HLS Solution 7 with loop1 pipelined Latency Summary (clock cycles)	$\frac{35}{35}$
65	HLS Solution 7 with loop1 pipelined Latency Loops Summary	35
66	HLS Solution 7 with loop1 pipelined Utilization Estimates Summary	$\frac{36}{36}$
	HLS Solution 7 with loop1 pipelined C/RTL Cosimulation Summary	$\frac{30}{36}$
67 co	HLS Solution 7 with loop1 pipelined Export RTL Resource Usage	$\frac{30}{36}$
68 60	1 1 1	
69 70	HLS Solution 7 with loop1 pipelined Export RTL Final Timing	36
70 71		38
71	HLS Solution 8 Latency Summary (clock cycles)	38
72		39
73	HLS Solution 8 Utilization Estimates [#]	39
74	HLS Solution 8 C/RTL Cosimulation Report	39
75 70	HLS Solution 8 Export RTL Report	39
76 77	HLS Solution 9 Timing Summary (ns)	40
77	HLS Solution 9 Latency Summary (clock cycles)	40
78	HLS Solution 9 Latency Loops Summary	40
79	HLS Solution 9 with columnIndex partitioning Latency Loops Summary	41
80		
81	HLS Solution 9 with columnIndex, values and x partitioning Latency Loops Summary	
82	HLS Solution 9 with columnIndex, values, x and rowPtr partitioning Latency Loops Summary	
83	HLS Solution 9 with columnIndex, values, x, rowPtr and y partitioning Latency Loops Summary	44
84	HLS Solution 9 with columnIndex, values and x partitioning and loop1 pipelined Latency	
~ -	Loops Summary	44
85	HLS Solution 9 with columnIndex, values and x partitioning and loop1 pipelined C/RTL	
0.0	Cosimulation Summary	45
86	HLS Solution 9 with columnIndex, values and x partitioning and loop1 pipelined Export RTL	۔ ،
	Resource Usage	45
87	HLS Solution 9 with columnIndex, values and x partitioning and loop1 pipelined Export RTL	
	Final Timing	45
88	HLS Solution 10 Timing Summary (ns)	48
89	HLS Solution 10 Latency Summary (clock cycles)	49
90	HLS Solution 10 Latency Loops Summary	49
91	HLS Solution 10 Utilization Estimates [#]	49
92	HLS Solution 10 C/RTL Cosimulation Report	50
93	HLS Solution 10 Export RTL Report	51
94	HLS Solution 11 Timing Summary (ns)	54

95	HLS Solution 11 Latency Summary (clock cycles)	54
96	HLS Solution 11 Latency Loops Summary	54
97	HLS Solution 11 Utilization Estimates [#]	54
	HLS Solution 11 C/RTL Cosimulation Report	
99	HLS Solution 11 Export RTL Report	55
100	HLS Conclusions C/RTL Cosimulation Report	56
101	HLS Conclusions Export RTL Report	58

1 Introduction

1.1 Sparse Matrix

Nell'analisi numerica, una **matrice sparsa** è una matrice in cui la maggior parte degli elementi è pari a zero. Non esiste una definizione rigorosa della proporzione di elementi a valore nullo affinché una matrice possa essere considerata sparsa. Al contrario, se la maggior parte degli elementi è non nulla, allora la matrice è considerata densa.

Una matrice è tipicamente memorizzata come un array bidimensionale. Ogni voce della matrice rappresenta un elemento $a_{i,j}$ della matrice e vi si accede tramite i due indici i e j. Per una matrice m \times n, la quantità di memoria necessaria per memorizzare la matrice in questo formato è proporzionale a m \times n (senza considerare che è necessario memorizzare anche le dimensioni relative alla matrice).

Nel caso di una matrice sparsa, è possibile ridurre notevolmente i requisiti di memoria memorizzando solo le voci non nulle. A seconda del numero e della distribuzione delle voci non nulle, è possibile utilizzare diverse strutture di dati che consentono di ottenere enormi risparmi di memoria rispetto all'approccio di base. Il compromesso è che l'accesso ai singoli elementi diventa più complesso e sono necessarie strutture aggiuntive per poter recuperare la matrice originale senza ambiguità.

I formati possono essere divisi in due gruppi:

- Quelli che supportano una modifica efficiente, come DOK (Dictionary of Keys), LIL (List of Lists) o COO (Coordinate List), utilizzati solitamente per la costruzione della matrice.
- Quelli che supportano l'accesso e le operazioni matriciali efficienti, come CRS (Compressed Row Storage) o CCS (Compressed Column Storage).

1.2 Compressed Row Storage (CRS)

Il formato Compressed Row Storage (CRS) permette la rappresentazione di una matrice tramite tre array unidimensionali consentendo un accesso veloce alle righe e una moltiplicazione matrice-vettore efficiente. In particolare, i tre array utilizzati sono i seguenti:

- values
 - È un array contenente tutti gli elementi della matrice non nulli.
- rowPtr
 - È un array contenente gli indici, relativi all'array values, corrispondenti ai primi elementi non nulli di ogni riga.
- columnIndex
 - È un array contenente gli indici di colonna degli elementi non nulli.

2 Tasks to be performed

Prendendo come riferimento il formato CRS per il calcolo del prodotto tra una matrice sparsa ed un vettore e considerando il tool di sintesi ad alto livello per sistemi digitali, fornito da Xilinx $^{\circledR}$, analizzare le soluzioni proposte nella seguente tabella utilizzando le direttive proprietarie citate e caratterizzando in termini di latenza e utilizzazione delle risorse.

Solution	Loop1	Loop2	
1	-	-	
2	-	Pipeline	
3	Pipeline	-	
4	Unroll=2	-	
5	-	Pipeline, Unroll=2	
6 - Pipeline, Ur		Pipeline, Unroll=2, Cyclic=2	
7 - Pipeline, Unroll=4		Pipeline, Unroll=4	
8	-	Pipeline, Unroll=2, Cyclic=4	
9	-	Pipeline, Unroll=8	
10	-	Pipeline, Unroll=2, Cyclic=8	
11	-	Pipeline, Unroll=2, Block=8	

Table 1: SMVM Solutions To Be Performed

3 Definitions

Qui di seguito vengono riportate le definizioni e le intestazioni dei metodi corrispondenti alle soluzioni implementate per la moltiplicazione tra una matrice sparsa e un vettore. In particolare, ogni definizione presenta la documentazione associata. Inoltre, è stata prevista l'implementazione per la moltiplicazione standard così da poter verificare i risultati ottenuti tramite formato CRS.

```
#ifndef DEFINITIONS_H
4 /**
* Square Matrix Size.
7 const static int size = 4;
9 /**
  * Number of Non-Zero Elements.
10
11
  */
12 const static int nnz = 9;
14 /**
* Number of Rows.
16
17 const static int rows = 4;
18
19 /**
20 * Data Type.
21 */
typedef int DTYPE;
24 /**
  * Matrix Vector Standard Multiplication Design.
25
  * @param matrix[size][size] Input matrix
26
  * @param y Multiplication Result
27
* Cparam x Input Vector
29 */
void std_multiplication(DTYPE matrix[size][size], DTYPE *y, DTYPE *x);
31
32 /**
* Sparse Matrix Vector Multiplication Design (CRS format).
  * @param rowPtr[rows+1] Indexes First Elements
34
  * @param columnIndex[nnz] Indexes Non Zero Elements
  * @param values[nnz] Input Values
36
  * Oparam y[size] Multiplication Result
37
  * @param x[size] Input Vector
38
39 */
40 void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
     x[size]);
41
42
43 #endif
```

4 C Simulations

Qui di seguito viene riportato il file testbench per la C Simulation in HLS e il corrispondente output ottenuto. In particolare, qui di seguito verrà riportato il caso in cui venga scelta la prima configurazione con matrice di dimensione 4 * 4. Le altre configurazioni, relative ad alcune solution implementate, verranno presentate nei paragrafi successivi.

```
#include "definitions.h"
#include <iostream>
3 using namespace std;
5 void std_multiplication(DTYPE matrix[size][size], DTYPE *y, DTYPE *x);
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
       x[size]):
  int main() {
9
10
    int fail = 0;
    DTYPE matrix[size][size] = {
12
      {3,4,0,0},
       {0,5,9,0},
14
15
       {2,0,3,1},
      {0,4,0,6}
17
    DTYPE x[size] = \{1, 1, 1, 1\};
18
    DTYPE values[] = {3, 4, 5, 9, 2, 3, 1, 4, 6};
int columnIndex[] = {0, 1, 1, 2, 0, 2, 3, 1, 3};
19
20
    int rowPtr[] = {0,2,4,7,9};
21
22
23
    DTYPE matrix[size][size] = {
24
       {3, 4, 0, 0, 0, 0, 0, 0},
25
       \{0, 5, 9, 0, 0, 0, 0, 0\},\
26
       {2, 0, 3, 1, 0, 0, 0, 0},
27
       {0, 4, 0, 6, 0, 0, 0, 0},
28
       {0, 0, 0, 0, 0, 0, 0, 0},
29
       {0, 0, 0, 0, 0, 0, 0, 0},
30
       {0, 0, 0, 0, 0, 0, 0, 0},
31
       {0, 0, 0, 0, 0, 0, 0, 0}
32
33
    DTYPE x[size] = {1, 1, 1, 1, 1, 1, 1};
34
    DTYPE values[] = {3, 4, 5, 9, 2, 3, 1, 4, 6};
35
    int columnIndex[] = {0, 1, 1, 2, 0, 2, 3, 1, 3};
36
    int rowPtr[] = {0, 2, 4, 7, 9, 9, 9, 9};
37
    */
38
    /*
39
    DTYPE matrix[size][size] = {
40
       {3, 4, 0, 0, 0, 0, 0, 0},
41
       {0, 5, 9, 0, 0, 0, 0, 0},
42
       {2, 0, 3, 1, 0, 0, 0, 0},
43
       \{0, 4, 0, 6, 0, 0, 0, 0\},\
44
       {1, 0, 0, 0, 0, 0, 0, 0},
45
       {1, 1, 0, 0, 0, 0, 0, 0},
46
       {1, 1, 0, 0, 0, 0, 0, 0},
47
       {1, 1, 0, 0, 0, 0, 0, 0}
48
    };
49
    DTYPE x[size] = {1, 1, 1, 1, 1, 1, 1};
50
    DTYPE values[] = {3, 4, 5, 9, 2, 3, 1, 4, 6, 1, 1, 1, 1, 1, 1, 1};
    int columnIndex[] = {0, 1, 1, 2, 0, 2, 3, 1, 3, 0, 0, 1, 0, 1};
int rowPtr[] = {0, 2, 4, 7, 9, 10, 12, 14, 16};
52
54
55
    DTYPE ystd[size];
56
    std_multiplication(matrix, ystd, x);
57
58
    DTYPE y[size];
    smvm(rowPtr, columnIndex, values, y, x);
```

```
cout << endl;</pre>
60
    for(int i=0; i<size; ++i) {</pre>
61
     cout << "ystd=" << ystd[i] << ", ";
62
      cout << "y=" << y[i] << endl;
63
     if(ystd[i] != y[i])
64
      fail = 1;
if(fail == 1)
65
66
       cout << "i=" << i << " failed." << endl;</pre>
67
        cout << "i=" << i << " passed." << endl;</pre>
69
70
    cout << endl;</pre>
71
72
    return fail;
73
74 }
2 INFO: [SIM 211-4] CSIM will launch GCC as the compiler.
3 Compiling ../../smvmTB.cpp in debug mode
4 Compiling ../../smvm.cpp in debug mode
5 Compiling ../../stdm.cpp in debug mode
6 Generating csim.exe
8 \text{ ystd=7, y=7}
```

9 i=0 passed.

10 ystd=14, y=14

11 i=1 passed.

12 ystd=6, y=6

13 i=2 passed.

14 ystd=10, y=10

15 i=3 passed.

19 Finished C simulation.

17 INFO: [SIM 211-1] CSim done with 0 errors.

Nello specifico, qui di seguito, viene riportata l'implementazione della moltiplicazione standard utilizzata per verificare i risultati sopra allegati.

```
#include "definitions.h"

void std_multiplication(DTYPE matrix[size][size], DTYPE *y, DTYPE *x) {

for (int i = 0; i < size; i++) {

   DTYPE ytmp = 0;

   for (int j = 0; j < size; j++)

      ytmp += matrix[i][j] * x[j];

   y[i] = ytmp;

}

}</pre>
```

5 Solutions

Di seguito verranno illustrate e analizzate le soluzioni previste nella tabella sotto allegata.

Nello specifico, nelle implementazioni dove è previsto l'utilizzo della direttiva di partitioning sono stati considerati tre array (columnIndex, values, x) a cui corrispondono quattro solution differenti. In particolare, è stata prevista una soluzione in cui viene effettuato il partitioning di tutte e tre gli array contemporaneamente e le rimanenti tre implementazioni in cui, per ognuna di essa, è stato previsto il partizionamento singolo di uno dei tre array appena citati. Tali implementazioni sono riportate qui di seguito.

Solution	Loop1	Loop2		
1	-	-		
2	-	Pipeline		
3	Pipeline	-		
4	Unroll=2	-		
5	-	Pipeline, Unroll=2		
6	-	Pipeline, Unroll=2, Cyclic=2		
	-	• Pipeline, Unroll=2, Cyclic=2 (columnIndex)		
	-	• Pipeline, Unroll=2, Cyclic=2 (values)		
	-	• Pipeline, Unroll=2, Cyclic=2 (x)		
	-	• Pipeline, Unroll=2, Cyclic=2 (columnIndex, values, x)		
7	-	Pipeline, Unroll=4		
8	-	Pipeline, Unroll=2, Cyclic=4		
	-	• Pipeline, Unroll=2, Cyclic=4 (columnIndex)		
	-	• Pipeline, Unroll=2, Cyclic=4 (values)		
	-	• Pipeline, Unroll=2, Cyclic=4 (x)		
	-	• Pipeline, Unroll=2, Cyclic=4 (columnIndex, values, x)		
9	-	Pipeline, Unroll=8		
10	-	Pipeline, Unroll=2, Cyclic=8		
	-	• Pipeline, Unroll=2, Cyclic=8 (columnIndex)		
	-	• Pipeline, Unroll=2, Cyclic=8 (values)		
	-	• Pipeline, Unroll=2, Cyclic=8 (x)		
	-	• Pipeline, Unroll=2, Cyclic=8 (columnIndex, values, x)		
11	-	Pipeline, Unroll=2, Block=8		
	-	• Pipeline, Unroll=2, Block=8 (columnIndex)		
	-	• Pipeline, Unroll=2, Block=8 (values)		
	-	• Pipeline, Unroll=2, Block=8 (x)		
	-	• Pipeline, Unroll=2, Block=8 (columnIndex, values, x)		

Table 2: SMVM Solutions To Be Performed

5.1 Solution 1

Qui, di seguito, viene riportata l'architettura relativa alla prima solution.

```
#include "definitions.h"

void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE x[size]) {
    loop1: for (int i=0; i<rows; i++) {
        DTYPE ytmp = 0;
        loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {
            ytmp += values[k] * x[columnIndex[k]];
        }
        y[i] = ytmp;
    }
}</pre>
```

Si può notare come venga utilizzata una variabile temporanea ytmp poiché essa viene utilizzata per calcolare l'uscita corrispondente. In particolare, il risultato calcolato ad ogni iterazione viene sommato a quello della precedente iterazione. Pertanto, essendo che l'uscita deve essere solo assegnata e non letta per ogni iterazione, si utilizza una variabile temporanea per calcolare il risultato. Solo alla fine delle iterazioni si potrà assegnare il risultato all'uscita corrispondente.

Effettuando la sintesi è possibile evidenziare il seguente report:

Clock	Target	Estimated	Uncertainty	
ap_clk	10.00	8.510	1.25	

Table 3: HLS Solution 1 without Trip Count Timing Summary (ns)

Late	ency	Inte	erval
\min	max	min	max
?	?	?	?

Table 4: HLS Solution 1 without Trip Count Latency Summary (clock cycles)

I	Loop	Latency		Iteration Latency	Initiation Interval		Trip Count
l N	Vame	min	max		achieved	target	
-	loop1	?	?	?	-	-	4
+	loop2	?	?	5	-	-	?

Table 5: HLS Solution 1 without Trip Count Latency Loops Summary

Si può notare come la latenza associata a questa architettura risulta essere "?", cioè non definita. In particolare tale non definizione è dovuta al loop2 del quale non è definito il trip count associato essendo il numero di iterazioni corrispondente non noto a priori. Nello specifico, il ciclo 2 dipende dai valori presenti all'interno dell'array columnIndex che non sono incogniti poiché dipendono dai valori in input all'architettura. Viceversa, la latenza per ogni iterazione (IL), essendo che dipende dalla tipologia di operazioni, risulta essere definita. Per quanto riguarda, invece, il loop1, esso presenta un'iteration latency non definita poiché dipendente direttamente dal loop2 di cui non si è a conoscenza della latenza totale come spiegato precedentemente. Pertanto, la latenza totale del loop1 e, di conseguenza, la latenza totale associata all'architettura risulta essere non nota a priori. Quindi, per poter risolvere si specifica all'interno dell'implementazione la direttiva trip_count. In particolare, si possono specificare tre valori all'interno di tale pragma: min, max e avg. Tali valori fanno riferimento rispettivamente al numero minimo, massimo e medio di iterazioni del loop di riferimento. Pertanto, tale direttiva permette al tool di analizare come la latenza del loop contribuisce alla latenza totale dell'architettura così permettendo al progettista di effettuare ulteriori ottimizzazioni al design.

Pertanto, si allega l'architettura risultante.

```
#include "definitions.h"

void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE x[size]) {
```

```
loop1: for (int i=0; i<rows; i++) {
    DTYPE ytmp = 0;
    loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        ytmp += values[k] * x[columnIndex[k]];
    }
    y[i] = ytmp;
}</pre>
```

Effettuando la sintesi è possibile evidenziare il seguente report:

Clock Target		Estimated	Uncertainty	
ap_clk	10.00	8.510	1.25	

 Latency
 Interval

 min
 max
 min
 max

 13
 93
 13
 93

Table 6: HLS Solution 1 with Trip Count Timing Summary (ns)

Table 7: HLS Solution 1 with Trip Count Latency Summary (clock cycles)

Loop	Latency		Iteration Latency	Initiation Interval		Trip Count
Name	min	max		achieved	target	
- loop1	12	92	3~23	-	-	4
+ loop2	0	20	5	-	-	0~4

Table 8: HLS Solution 1 Latency with Trip Count Loops Summary

Si può notare come, dopo aver applicato la direttiva di trip_count, i valori di latenza risultano essere definiti numericamente. In particolare, il loop2 presenta un numero di iterazioni compresa tra 0 e 4, cioè rispettivamente il valore minimo e massimo specificati nel pragma di trip_count. Bisogna ricordare che tale direttiva non ha impatto sull'architettura ma ha solo impatto sui cicli di latenza.

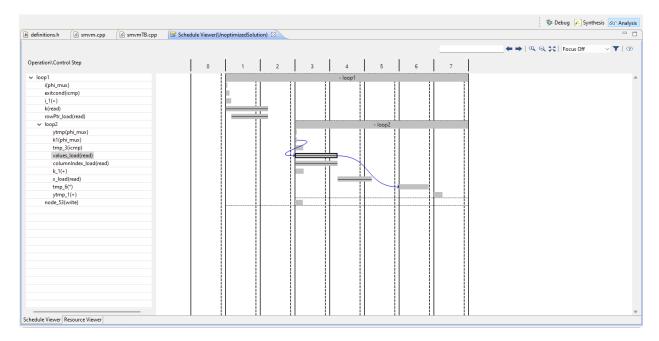


Figure 1: HLS Solution 1 Analysis

Qui di seguito, viene allegato l'utilizzazione delle risorse stimata dal processo di sintesi.

Name	BRAM_18K	DSP48E	\mathbf{FF}	LUT
DSP	-	-	-	
Expression	-	3	0	137
FIFO	-	-	-	-
Instance	-	-	_	-
Memory	0	-	_	-
Multiplexer	-	-	_	71
Register	-	-	241	-
Total	0	3	241	208
Available	280	220	106400	53200
Utilization (%)	0	1	~0	~0

Table 9: HLS Solution 1 with Trip Count Utilization Estimates Summary

Successivamente effettuando la ${\rm C/RTL}$ Cosimulation e l'Export ${\rm RTL}$ è possibile evidenziare i seguenti report.

RTL	Status	Latency		I	nterva	al	
		min	avg	max	min	avg	max
VHDL	Pass	58	58	58	NA	NA	NA

Table 10: HLS Solution 1 with Trip Count C/RTL Cosimulation Summary

Resource	VHDL
SLICE	48
LUT	93
FF	161
DSP	3
BRAM	0
SRL	0

Table 11: HLS Solution 1 with Trip Count Export RTL Resource Usage $\,$

Timing	VHDL
CP required	10.000
CP achieved post-synthesis	5.745
CP achieved post-implementation	5.692

Table 12: HLS Solution 1 with Trip Count Export RTL Final Timing

5.2 Solution 2

Qui, di seguito, viene riportata l'architettura relativa alla seconda solution.

In particolare, nella soluzione hardware in questione, rispetto alla solution 1, è stato aggiunto la direttiva di pipeline all'interno del loop2. Pertanto, ci si dovrebbe aspettare una minore latenza totale dal momento che il pipelining permette di scindere le operazioni complesse in più operazioni semplici. In questo modo si può far lavorare l'architettura con dati temporalmente differenti.

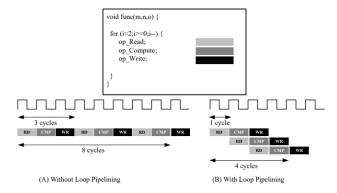


Figure 2: HLS Loop Pipelining

Effettuando la sintesi è possibile evidenziare il seguente report:

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.510	1.25

	Table 13:	HLS	Solution	2	Timing	Summary	(ns)
--	-----------	-----	----------	---	--------	---------	-----	---

Late	ency	Interval		
\min	max	min	max	
17	45	17	45	

Table 14: HLS Solution 2 Latency Summary (clock cycles)

Loop	Latency		Iteration Latency	Initiation Interval		Trip Count
Name	min	max		achieved	target	
- loop1	16	44	4~11	-	-	4
+ loop2	0	7	5	1	1	0~4

Table 15: HLS Solution 2 Latency Loops Summary

Si può notare, rispetto alla solution precedente, come in questo caso venga specificato un valore numerico di Initiation Interval (II). In particolare, l'II_achieved risulta essere il medesimo di quello target, cioè uguale

a 1. Teoricamente, come in questo caso, si dovrebbe ottenere II_target=II_achieved. Se così non fosse allora il tool non è riuscito a raggiungere l'obiettivo prefissato e si dovrebbero attuare modifiche all'architetture o caso mai prevedere l'utilizzo di ulteriori direttive.

Qui di seguito, viene allegato l'utilizzazione delle risorse stimata dal processo di sintesi.

Name	BRAM_18K	DSP48E	FF	LUT
DSP	-	-	-	-
Expression	-	3	0	141
FIFO	-	-	-	-
Instance	-	-	_	-
Memory	0	-	_	-
Multiplexer	-	-	_	78
Register	-	-	340	32
Total	0	3	340	251
Available	280	220	106400	53200
Utilization (%)	0	1	~0	~0

Table 16: HLS Solution 2 Utilization Estimates Summary

Successivamente effettuando la C/RTL Cosimulation e l'Export RTL è possibile evidenziare i seguenti report.

	RTL	Status	Latency		I	nterva	al	
			min	avg	max	min	avg	max
ſ	VHDL	Pass	38	38	38	NA	NA	NA

Table 17: HLS Solution 1 with Trip Count C/RTL Cosimulation Summary

In particolare, si può notare come, in seguito all'introduzione della direttiva di pipeline, il numero di risorse risulta essere cambiato. Nello specifico, l'utilizzazione delle LUT è aumentata di circa il 24% mentre quella dei FF è diminuita di circa il 14%.

Resource	VHDL
SLICE	38
LUT	115
FF	139
DSP	3
BRAM	0
SRL	0

Table 18: HLS Solution 2t Export RTL Resource Usage

Timing	VHDL
CP required	10.000
CP achieved post-synthesis	5.745
CP achieved post-implementation	5.718

Table 19: HLS Solution 2 Export RTL Final Timing

5.3 Solution 3

Qui, di seguito, viene riportata l'architettura relativa alla terza solution.

```
#include "definitions.h"
  #include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE v[size]. DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      #pragma HLS pipeline
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
9
         #pragma HLS loop_tripcount min=0 max=4 avg=2
         ytmp += values[k] * x[columnIndex[k]];
11
12
13
      y[i] = ytmp;
14
15 }
```

In particolare, nella soluzione hardware in questione, rispetto alla solution 1, è stato aggiunta la direttiva di pipeline all'interno del loop1.

Effettuando la sintesi è possibile evidenziare il seguente report:

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.510	1.25

Late	ency	Inte	erval
min	max	min	max
13	93	13	93

Table 20: HLS Solution 3 Timing Summary (ns)

Table 21: HLS Solution 3 Latency Summary (clock cycles)

Loop	Latency		Iteration Latency	Initiation Interval		Trip Count
Name	min	max		achieved	target	
- loop1	12	92	3~23	-	-	4
+ loop2	0	20	5	_	_	$0 \sim 4$

Table 22: HLS Solution 3 Latency Loops Summary

Si può notare come, in questo caso l'Initiation Interval sia non specificato nel loop2 dal momento che la direttiva introdotta nella solution 2 è stata eliminata per la soluzione hardware in questione. Molto più importante è che, considerando la direttiva di pipeline definita all'interno del loop1, in corrispondenza dell'Initiation Interval di tale ciclo non è definito alcun valore numerico. Tanto è vero che, analizzando i log della sintesi presenti nella console è possibile identificare il seguente warning.

WARNING: [SCHED 204-65] Unable to satisfy pipeline directive: Loop contains subloop(s) not being unrolled or flattened.

In particolare, è come se il tool non riuscisse a soddisfare la richiesta di pipeline per il loop1 effettuata tramite la direttiva proprietaria. Questo potrebbe essere giustificato dal fatto che effettivamente la scissione dell'operazione "complessa" in micro-operazioni, all'interno del ciclo in questione, non è possibile effettuarla. Infatti, si può notare come i valori di latenza siano i medesimi di quelli della solution 1. Effettivamente, si potrebbe aggiungere la direttiva di pipeline all'interno del loop2, come fatto per la solution 2, dove sono presenti la maggior parte delle operazioni. In quel caso, infatti, il tool è riuscito a scomporre in micro-operazioni e così da permettere una minore latenza dal momento che i moduli potevano essere utilizzati da dati temporalmente differenti. Quello che si può notare è che nel loop1 le operazioni risultano essere l'inizializzazione della variabile temporanea ytmp, le operazioni interne al loop2 e la scrittura del valore di ytmp in y. Pertanto, le uniche operazioni complesse che potrebbero essere gestite tramite una direttiva di pipeline si trovano all'interno del loop2.

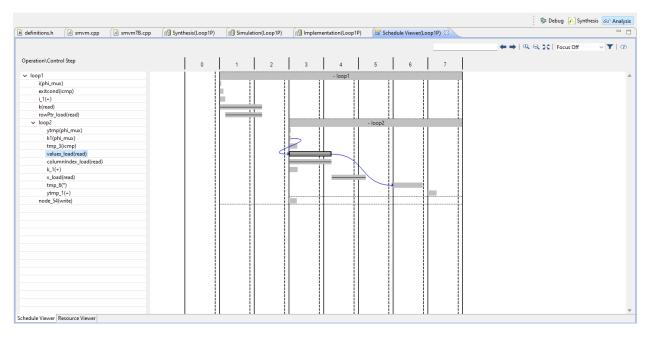


Figure 3: HLS Solution 3 Analysis

Qui di seguito, viene allegato l'utilizzazione delle risorse stimata dal processo di sintesi. Anche in questo caso il numero di risorse è il medesimo di quello ottenuto in corrispondenza della solution 1.

Name	BRAM_18K	DSP48E	FF	LUT
DSP	-	-	-	-
Expression	-	3	0	137
FIFO	-	-	_	-
Instance	-	-	_	-
Memory	0	-	-	-
Multiplexer	-	-	-	71
Register	-	-	241	-
Total	0	3	241	208
Available	280	220	106400	53200
Utilization (%)	0	1	~0	~0

Table 23: HLS Solution 3 Utilization Estimates Summary

Successivamente effettuando la C/RTL Cosimulation e l'Export RTL è possibile evidenziare i seguenti report. Anche in questo caso, sia il report del C/RTL Cosimulation sia quello dell'Export RTL risultano essere i medesimi di quelli della solution 1.

RTL	Status	Latency		I	nterva	al	
		min	avg	max	min	avg	max
VHDL	Pass	58	58	58	NA	NA	NA

Table 24: HLS Solution 1 with Trip Count C/RTL Cosimulation Summary

Resource	VHDL
SLICE	48
LUT	94
FF	161
DSP	3
BRAM	0
SRL	0

Table 25: HLS Solution 2t Export RTL Resource Usage

Timing	VHDL
CP required	10.000
CP achieved post-synthesis	5.745
CP achieved post-implementation	5.692

Table 26: HLS Solution 2 Export RTL Final Timing

Pertanto, considerando la solution in questione, la si potrebbe modificare aggiungendo la direttiva di pipeline anche nel loop2 per capire se le ipotesi, effettuate precedentemente, possono essere confermate o meno.

```
#include "definitions.h"
  #include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      #pragma HLS pipeline
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
9
         #pragma HLS loop_tripcount min=0 max=4 avg=2
10
         #pragma HLS pipeline
11
         ytmp += values[k] * x[columnIndex[k]];
12
13
      y[i] = ytmp;
14
15
16 }
```

Adottando questo approccio, però, la nuova soluzione hardware in questione si ricondurrebbe alla solution 2 precedentemente analizzata dal momento che la direttiva di pipeline nel loop1 verrebbe comunque ignorata e quello che verrebbe effettivamente attuato sarebbe il pragma di pipeline all'interno del loop2. Infatti, effettuando la sintesi si può notare come sia presente il medeesimo warning, alleegato precedentemente, e come sia i valori di latenza sia quelli dell'utilizzazione delle risorse siano i medesimi.

WARNING: [SCHED 204-65] Unable to satisfy pipeline directive: Loop contains subloop(s) not being unrolled or flattened.

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.510	1.25

Table 27: HLS Solution 3 Modified Timing Summary (ns)

Late	ency	Inte	erval
\min	max	\min	max
17	45	17	45

Table 28: HLS Solution 3 Modified Latency Summary (clock cycles)

Loop	Latency		Iteration Latency	Initiation Interval		Trip Count
Name	min	max		achieved	target	
- loop1	16	44	4~11	-	-	4
+ loop2	0	7	5	1	1	0~4

Table 29: HLS Solution 3 Modified Latency Loops Summary

Name	BRAM_18K	DSP48E	FF	LUT
DSP	-	-	-	-
Expression	-	3	0	141
FIFO	-	-	-	-
Instance	-	-	-	-
Memory	0	-	_	-
Multiplexer	-	-	-	78
Register	-	-	340	32
Total	0	3	340	251
Available	280	220	106400	53200
Utilization (%)	0	1	~0	~0

Table 30: HLS Solution 3 Modified Utilization Estimates Summary

5.4 Solution 4

Qui, di seguito, viene riportata l'architettura relativa alla quarta solution.

```
#include "definitions.h"
  #include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      #pragma HLS unroll factor=2
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
9
         #pragma HLS loop_tripcount min=0 max=4 avg=2
10
         ytmp += values[k] * x[columnIndex[k]];
11
12
13
      y[i] = ytmp;
14
15 }
```

In particolare, nella soluzione hardware in questione, rispetto alla solution 1, è stata aggiunta la direttiva di unrolling con fattore pari a 2 all'interno del loop1.

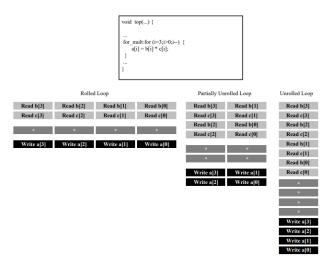


Figure 4: HLS Loop Unrolling

Effettuando la sintesi è possibile evidenziare il seguente report:

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.510	1.25

Table 31: HLS Solution 4 Timing Summary (ns)

Late	ency	Inte	erval
\min	max	min	max
11	91	11	91

Table 32: HLS Solution 4 Latency Summary (clock cycles)

In particolare, si può notare come il valore di trip count del loop1 risulta essere dimezzato rispetto alla solution 1. Questo è dovuto all'attuazione della direttiva di unrolling di fattore 2 sul loop1 e così permettendo l'esecuzione in parallelo di due iterazioni.

Loop	Latency		Iteration Latency	Initiation Interval		Trip Count
Name	\min	max		achieved	target	
- loop1	10	90	5~45	-	-	2
+ loop2	0	20	5	-	-	0~4
+ loop2	0	20	5	-	-	0~4

Table 33: HLS Solution 4 Latency Loops Summary

Infatti, lo si può meglio notare tramite l'interfaccia analysis. In particolare, si può evidenziare come il loop1 venga parallelizzato. Nello specifico, vengono previsti due loop2 uno dopo l'altro facendo così aumentare la latenza per ogni iterazione del loop1. Quindi, il valore del trip count associato al ciclo 1 viene dimezzato mentre l'Iteration Latency associata allo stesso loop viene sostanzialmente raddoppiata.

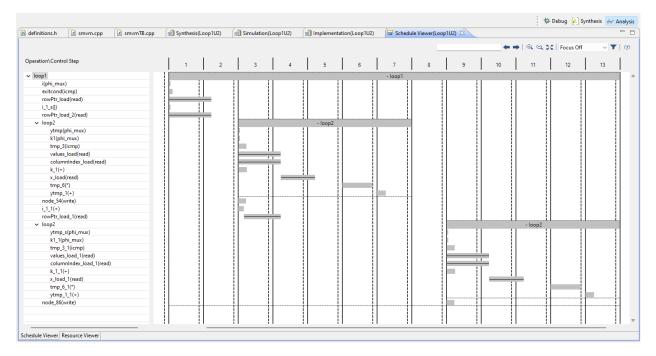


Figure 5: HLS Solution 4 Analysis

Name	BRAM_18K	DSP48E	\mathbf{FF}	LUT
DSP	-	-	-	-
Expression	-	3	0	235
FIFO	-	-	-	-
Instance	-	-	-	-
Memory	0	-	_	-
Multiplexer	-	-	_	197
Register	-	-	376	-
Total	0	3	376	432
Available	280	220	106400	53200
Utilization (%)	0	1	~0	~0

Table 34: HLS Solution 4 Utilization Estimates Summary

Successivamente effettuando la C/RTL Cosimulation e l'Export RTL è possibile evidenziare i seguenti report.

RTL	Status	Latency			I	nterv	al
		min	avg	max	min	avg	max
VHDL	Pass	56	56	56	NA	NA	NA

Table 35: HLS Solution 4 C/RTL Cosimulation Summary

In particolare, rispetto alla solution 1 si ha un aumento del 100% e di circa l'81% rispettivamente dell'utilizzazione delle LUT e dei FF dal momento che è stato introdotto un parallelismo all'interno dell'architettura.

Resource	VHDL
SLICE	83
LUT	186
FF	292
DSP	3
BRAM	0
SRL	0

Table 36: HLS Solution 4 Export RTL Resource Usage

Timing	VHDL
CP required	10.000
CP achieved post-synthesis	5.745
CP achieved post-implementation	5.692

Table 37: HLS Solution 4 Export RTL Final Timing

5.5 Solution 5

Qui, di seguito, viene riportata l'architettura relativa alla quinta solution.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
         #pragma HLS loop_tripcount min=0 max=4 avg=2
         #pragma HLS pipeline
         #pragma HLS unroll factor=2
         ytmp += values[k] * x[columnIndex[k]];
11
      y[i]
12
           = ytmp;
    }
13
14 }
```

In particolare, nella soluzione hardware in questione, rispetto alla solution 2 dove era presenta solo la direttiva di unrolling nel loop2,, è stata aggiunta la direttiva di unrolling con fattore pari a 2 all'interno del loop2.

Effettuando la sintesi è possibile evidenziare il seguente report:

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.510	1.25

Late	ency	Inte	erval
\min	min max		max
33	41	33	41

Table 38: HLS Solution 5 Timing Summary (ns)

Table 39: HLS Solution 5 Latency Summary (clock cycles)

In particolare, si può notare come, rispetto alla solution 2 dove il trip count relativo al loop2 era pari a $0 \sim 4$, in questo caso il trip count associato al loop2 risulta essere dimezzato dal momento che è stato previsto un unrolling di fattore pari a 2 all'interno del ciclo in questione. Inoltre, dal momento che è stato introdotto una direttiva di pipeline all'interno del loop2, si può evidenziare come l'Initiation Interval raggiunto risulta essere il medesimo di quello target.

Loop	Latency		Iteration Latency	Initiation Interval		Trip Count
Name	min	max		achieved	target	
- loop1	32	40	8~10	-	-	4
+ loop2	4	6	5	1	1	$0\sim2$

Table 40: HLS Solution 5 Latency Loops Summary

Si può notare come, all'interno del loop2, vengono effettuate in parallelo due letture relative alle variabili columnIndex, due relative alle variabili values e due relative alle variabili x.

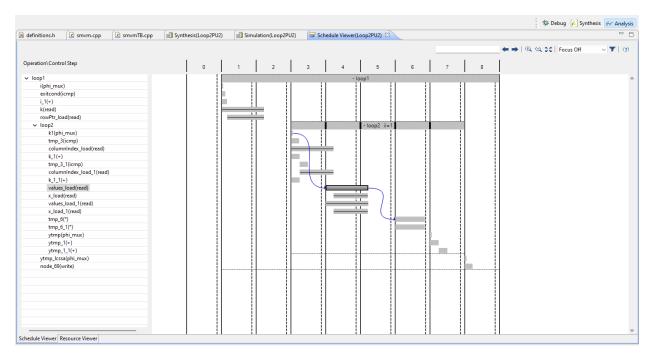


Figure 6: HLS Solution 5 Analysis

Name	BRAM_18K	DSP48E	FF	LUT
DSP	-	-	-	-
Expression	-	6	0	257
FIFO	-	-	-	-
Instance	-	-	-	-
Memory	0	-	-	-
Multiplexer	-	_	_	78
Register	-	-	597	64
Total	0	6	597	399
Available	280	220	106400	53200
Utilization (%)	0	2	~0	~0

Table 41: HLS Solution 5 Utilization Estimates Summary

R	ΓL	Status	Latency			I	nterva	al
			\min	avg	max	min	avg	max
VH	DL	Pass	37	37	37	NA	NA	NA

Table 42: HLS Solution 5 C/RTL Cosimulation Summary

Si può notare, rispetto alla soluzione hardware 2, un aumento dell'utilizzazione delle risorse del 60% per quanto riguarda le LUT e di circa il 41% per quanto riguarda i FF. Inoltre, si può evidenziare come il numero dei DSP sia raddoppiato.

Resource	VHDL
SLICE	69
LUT	184
FF	196
DSP	6
BRAM	0
SRL	0

Table 43: HLS Solution 5 Export RTL Resource Usage

Timing	VHDL
CP required	10.000
CP achieved post-synthesis	7.927
CP achieved post-implementation	7.465

Table 44: HLS Solution 5 Export RTL Final Timing

5.6 Solution 6

Qui, di seguito, vengono riportate le architetture relative alla sesta solution. In particolare, come già precedentemente citato, tale solution prevede l'utilizzo della direttiva di partitioning.

Il partizionamento serve per risolvere un problema tipicamente causato dagli array. Gli array sono implementati come BRAM, solitamente progettate per un dual-port massimo. Questo può limitare il throughput di un algoritmo ad alta intensità di read/write. La larghezza di banda può essere migliorata dividendo l'array (una singola BRAM) in array più piccoli (più BRAM), aumentando di fatto il numero di porte. Gli array vengono partizionati utilizzando la direttiva ARRAY_PARTITION. Vivado HLS offre tre tipi di partizionamento degli array. I tre tipi di partizionamento sono:

• block

L'array originale viene suddiviso in blocchi di uguali dimensioni di elementi consecutivi dell'array originale.

• cyclic

L'array originale viene suddiviso in blocchi di uguali dimensioni che interlacciano gli elementi dell'array originale.

• complete

L'operazione predefinita consiste nel dividere l'array nei suoi singoli elementi. Ciò corrisponde alla risoluzione di una memoria in registri.

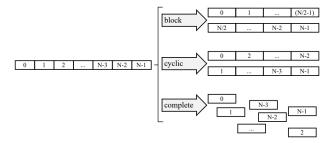


Figure 7: HLS Array Partitioning

Nella soluzione hardware in questione verrà utilizzata la direttiva di partizionamento di tipologia cyclic e nello specifico, verranno analizzate le seguenti implementazioni relative al loop2:

- Pipeline, Unroll=2, Cyclic=2 (columnIndex, values, x)
- Pipeline, Unroll=2, Cyclic=2 (columnIndex)
- Pipeline, Unroll=2, Cyclic=2 (values)
- Pipeline, Unroll=2, Cyclic=2 (x)

In particolare, è possibile evidenziare nel dettaglio le differenti soluzioni hardware nei seguenti allegati.

```
#include "definitions.h"

void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE x[size]) {
   loop1: for (int i=0; i<rows; i++) {
      DTYPE ytmp = 0;
   loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {
      #pragma HLS loop_tripcount min=0 max=4 avg=2
      #pragma HLS pipeline
      #pragma HLS unroll factor=2
      #pragma HLS array_partition variable=columnIndex cyclic factor=2
      #pragma HLS array_partition variable=values cyclic factor=2
      #pragma HLS array_partition variable=x cyclic factor=2
      #pragma HLS array_partition variable=x cyclic factor=2</pre>
```

```
ytmp += values[k] * x[columnIndex[k]];
13
14
      y[i] = ytmp;
15
16
17 }
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=2
        #pragma HLS array_partition variable=columnIndex cyclic factor=2
10
11
        ytmp += values[k] * x[columnIndex[k]];
12
      y[i] = ytmp;
13
14
15 }
#include "definitions.h"
2
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
5
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
8
9
        #pragma HLS unroll factor=2
        #pragma HLS array_partition variable=values cyclic factor=2
1.0
        ytmp += values[k] * x[columnIndex[k]];
11
12
      y[i] = ytmp;
13
14
15 }
#include "definitions.h"
3 void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
5
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
9
        #pragma HLS unroll factor=2
        #pragma HLS array_partition variable=x cyclic factor=2
10
11
        ytmp += values[k] * x[columnIndex[k]];
12
      y[i] = ytmp;
13
    }
14
15 }
```

Effettuando la sintesi è possibile evidenziare il seguente report:

Solution	Clock	Target	Estimated	Uncertainty
columnIndex, values, x	ap_clk	10.00	8.510	1.25
columnIndex	ap_clk	10.00	8.510	1.25
values	ap_clk	10.00	8.510	1.25
X	ap_clk	10.00	8.510	1.25

Table 45: HLS Solution 6 Timing Summary (ns)

Solution	Late	ency	Interval		
	min	max	min	max	
columnIndex, values, x	33	41	33	41	
columnIndex	33	41	33	41	
values	33	41	33	41	
x	33	41	33	41	

Table 46: HLS Solution 6 Latency Summary (clock cycles)

Si può notare come, in corrispondenza di tutte e quattro le soluzioni hardware proposte in questa sezione, i valori di Iteration Latency, trip count, Initiation Interval relativa al loop2 e latenza totale del loop1 e loop2 risultano essere i medesimi. In particolare, il valore di trip count del loop2 risulta essere dimezzato, come quello della solution5, rispetto, ad esempio, alla solution2 dal momento che è presente la direttiva di unrolling di fattore pari a 2.

Solution	Loop Name	Late	ency	Iteration Latency	Initiation	n Interval	Trip
		min	max		achieved	target	Count
columnIndex, values, x	- loop1	32	40	8~10	-	-	4
	+ loop2	4	6	5	1	1	0~2
columnIndex	- loop1	32	40	8~10	-	-	4
	+ loop2	4	6	5	1	1	$0 \sim 2$
values	- loop1	32	40	8~10	-	-	4
	+ loop2	4	6	5	1	1	$0\sim2$
X	- loop1	32	40	8~10	-	-	4
	+ loop2	4	6	5	1	1	$0 \sim 2$

Table 47: HLS Solution 6 Latency Loops Summary

Solution	BRAM_18K	DSP48E	FF	LUT
columnIndex, values, x	0	6	535	623
columnIndex	0	6	533	472
values	0	6	533	472
X	0	6	599	463

Table 48: HLS Solution 6 Utilization Estimates [#]

Si può evidenziare come i valori di latenza associati alle quattro solution proposte risultano essere i medesimi di quelli otteenuti in corrispondenza della soluzione hardware 5.

Solution	RTL	Status	Latency		Interval			
			min	avg	max	min	avg	max
columnIndex, values, x	VHDL	Pass	37	37	37	NA	NA	NA
columnIndex	VHDL	Pass	37	37	37	NA	NA	NA
values	VHDL	Pass	37	37	37	NA	NA	NA
x	VHDL	Pass	37	37	37	NA	NA	NA

Table 49: HLS Solution 6 C/RTL Cosimulation Report

Si può notare come, in corrispondenza della soluzione basata su partitioning dell'array columnIndex e dell'array values si ha la medesima utilizzazione dei FF. Molto probabilmente questo risultato è legato al fatto che entrambi gli array presentano medesima dimensione, cioè pari a nnz. Inoltre, la minore utilizzazione delle risorse si ha in corrispondenza dell'array x a cui corrisponde, infatti, la dimensione minore tra i tre array considerati. In particolare, la soluzione in cui viene considerato il partizionamento dei tre array potrebbe essere considerata come la solution che richiede più risorse dal momento che presenta il maggior numero di slice utilizzate.

Solution	SLICE	LUT	\mathbf{FF}	DSP	BRAM	CP	CP	CP
						required	achieved	achieved
							post-	post-
							synthesis	implementation
columnIndex, values, x	113	316	198	6	0	10	7.927	7.799
columnIndex	84	259	224	6	0	10	7.472	7.843
values	99	327	224	6	0	10	7.502	8.184
X	99	250	198	6	0	10	6.541	6.931

Table 50: HLS Solution 6 Export RTL Report

5.7 Solution 7

Qui, di seguito, viene riportata l'architettura relativa alla settima solution.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
         #pragma HLS loop_tripcount min=0 max=4 avg=2
         #pragma HLS pipeline
         #pragma HLS unroll factor=4
9
         ytmp += values[k] * x[columnIndex[k]];
11
      y[i] = ytmp;
12
    }
13
14 }
```

In particolare, rispetto alla soluzione hardware 5 dove era stato considerato un parallelismo di fattore pari a 2, in questa solution è stato considerato un unrolling di fattore pari a 4. In particolare, ciò che ci si aspetta è un aumento delle risorse ed eventuali problematiche relative al timing dal momento che il tool deve gestire all'interno del loop2 più accessi in memoria paralleli.

Effettuando la sintesi è possibile evidenziare il seguente log nella console:

WARNING: [SCHED 204-69] Unable to schedule 'load' operation ('columnIndex_load_2', smvmProject/s-mvm.cpp:34) on array 'columnIndex' due to limited memory ports. Please consider using a memory core with more ports or partitioning the array 'columnIndex'.

Tale log sta a significare che non riesce a schedulare correttamente, dal punto di vista degli accessi in memoria, la load operation relativa all'array *columnIndex* dato dal numero limitato di porte relative alla memoria. In particolare, analizzando il report relativo alla sintesi, si può notare come l'Initiation Interval, associato al loop2, raggiunto risulta essere maggiore di quello target.

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.510	1.25

Table 51: HLS Solution 7 Timing Summary (ns)

Late	ency	Inte	erval
\min	max	min	max
37	45	37	45

Table 52: HLS Solution 7 Latency Summary (clock cycles)

Loop	Latency		Iteration Latency	Initiation	n Interval	Trip Count
Name	min	max		achieved	target	
- loop1	36	44	9~11	-	-	4
+ loop2	5	7	6	2	1	0~1

Table 53: HLS Solution 7 Latency Loops Summary

Pertanto, si potrebbe aggiungere una direttiva di partizionamento relativa all'array menzionato all'interno del log, cioè *columnIndex*.

```
#include "definitions.h"

void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE x[size]) {
  loop1: for (int i=0; i<rows; i++) {
    DTYPE ytmp = 0;
  loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {
    #pragma HLS loop_tripcount min=0 max=4 avg=2
    #pragma HLS pipeline</pre>
```

```
#pragma HLS unroll factor=4
#pragma HLS array_partition variable=columnIndex cyclic factor=4
ytmp += values[k] * x[columnIndex[k]];

y[i] = ytmp;

y[i] = ytmp;

}
```

Effettuando nuovamente la sintesi, si ottiene il seguente log nella console e i seguenti valori di latenza. WARNING: [SCHED 204-69] Unable to schedule 'load' operation ('values_load_2', smvmProject/smvm.cpp:34) on array 'values' due to limited memory ports. Please consider using a memory core with more ports or partitioning the array 'values'.

Loop	Lat	ency	Iteration Latency	Initiation Interval		Trip Count
Name	min	max		achieved	target	
- loop1	. 36	44	9~11	-	-	4
+ loops	$2 \mid 5$	7	6	2	1	0~1

Table 54: HLS Solution 7 with columnIndex partitioning Latency Loops Summary

Si può notare come in questo caso il warning sia relativo all'array *values*. In particolare, la tipologia di warning è la medesima facendo presupporre che il tool non riesca a schedulare correttamente, secondo le direttive imposte dall'architetture, gli accessi in parallello all'array *values*. Infatti, il valore di Iteration Latency raggiunto risulta essere ancora maggiore di quello di quello target.

Pertanto, si potrebbe aggiungere una direttiva di partizionamento relativa all'array menzionato all'interno del log, cioè values.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
5
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=4
9
        #pragma HLS array_partition variable=columnIndex cyclic factor=4
        #pragma HLS array_partition variable=values cyclic factor=4
11
        ytmp += values[k] * x[columnIndex[k]];
12
      y[i] = ytmp;
14
15
16 }
```

Effettuando nuovamente la sintesi, si ottiene il seguente log nella console e i seguenti valori di latenza. WARNING: [SCHED 204-69] Unable to schedule 'load' operation ('x_load_2', smvmProject/smvm.cpp:34) on array 'x' due to limited memory ports. Please consider using a memory core with more ports or partitioning the array 'x'.

Loop	Latency		Iteration Latency	Initiation Interval		Trip Count
Name	min	max		achieved	target	
- loop1	36	44	9~11	-	-	4
+ loop2	5	7	6	2	1	0~1

Table 55: HLS Solution 7 with columnIndex and values partitioning Latency Loops Summary

Si può notare come in questo caso il warning sia relativo all'array x. In particolare, la tipologia di warning è la medesima della precedente. Anche in questo caso il valore di Iteration Latency raggiunto risulta essere ancora maggiore di quello di quello target.

Pertanto, si potrebbe aggiungere una direttiva di partizionamento relativa all'array menzionato all'interno del \log , cioè x.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=4
        #pragma HLS array_partition variable=columnIndex cyclic factor=4
        #pragma HLS array_partition variable=values cyclic factor=4
        #pragma HLS array_partition variable=x cyclic factor=4
        ytmp += values[k] * x[columnIndex[k]];
14
      y[i] = ytmp;
15
    }
16
17 }
```

Effettuando nuovamente la sintesi, si ottiene il seguente log nella console e il seguente report.

WARNING: [SCHED 204-21] Estimated clock period (10.208ns) exceeds the target (target clock period: 10ns, clock uncertainty: 1.25ns, effective delay budget: 8.75ns). WARNING: [SCHED 204-21] The critical path in module 'smvm' consists of the following:

```
'add' operation ('ytmp_1_3', smvmProject/smvm.cpp:34) [215] (2.55 ns)
```

'phi' operation ('ytmp', smvmProject/smvm.cpp:34) with incoming values : ('ytmp_1_3', smvmProject/smvm.cpp:34) [48] (0 ns)

```
'add' operation ('ytmp_1', smvmProject/smvm.cpp:34) [105] (2.55 ns)
```

'add' operation ('ytmp_1_1', smvmProject/smvm.cpp:34) [145] (2.55 ns)

'add' operation ('ytmp_1_2', smvmProject/smvm.cpp:34) [180] (2.55 ns)

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	10.208	1.25

Table 56: HLS Solution 7 with columnIndex, values and x partitioning Timing Summary (ns)

Lat	ency	Interval		
min	max	min	max	
37	41	37	41	

Table 57: HLS Solution 7 with columnIndex, values and x partitioning Latency Summary (clock cycles)

Loop	Latency		Iteration Latency	Initiation Interval		Trip Count
Name	min	max		achieved	target	
- loop1	36	40	9~10	-	-	4
+ loop2	5	6	6	1	1	0~1

Table 58: HLS Solution 7 with columnIndex, values and x partitioning Latency Loops Summary

Quello che si può notare è che all'interno della console viene visualizzato un warning indicante un periodo di clock stimato maggiore di quello target. In particolare, viene stimato un timing per ogni operazione in maniera dettagliata: 2.55ns per add operation ytmp_1_3, 0ns per phi operation ytmp, 2.55ns per add operation ytmp_1_1.2. Pertanto, calcolando la somma di tutti questi timing stimati si ottiene un periodo di clock stimato pari a 10.2ns. Nello specifico, il periodo di clock rimanente, cioè 0.008ns, evidentemente corrisponde al valore di timing relativo a phi operation ytmp che viene approssimato all'interno del report a 0ns.

Inoltre, si può notare come l'utilizzazione delle risorse sia notevolmente aumentata. In particolare, l'utilizzazione delle risorse, rispetto alle risorse disponibili della scheda, risultano essere pari al 5% per i DSP, all'1% per i FF e al 2% per le LUT.

Name	BRAM_18K	DSP48E	FF	LUT
DSP	-	-	-	-
Expression	-	12	0	848
FIFO	-	-	-	-
Instance	-	-	-	84
Memory	0	-	-	-
Multiplexer	-	-	-	321
Register	-	-	1338	128
Total	0	12	1338	1381
Available	280	220	106400	53200
Utilization (%)	0	5	1	2

Table 59: HLS Solution 7 with columnIndex, values and x partitioning Utilization Estimates Summary

Si procede con successivi passi così da verificare se tale problematica, riguardo il periodo di clock stimato superiore a quello target, possa essere risolta dal tool, tramite ulteriori ottimizzazioni, durante la fase di Export RTL.

RTL	Status	Latency			I	nterva	al
		min	avg	max	min	avg	max
VHDL	Pass	37	37	37	NA	NA	NA

Table 60: HLS Solution 7 with columnIndex, values and x partitioning C/RTL Cosimulation Summary

Si può notare come il tool sia riuscito a risolvere la problematica riguardante il periodo di clock stimato superiore a quello target. Infatti, si evidenzia come quello raggiunto post-implementation risulta essere pari a 7.974ns. Bisogna notare, però, che l'utilizzazione delle risorse risulta essere notevolmente alta dal momento che il tool ha attuato i partizionamenti di fattore pari a 4 su tutti e tre gli array precedentemente citati.

Resource	VHDL
SLICE	264
LUT	723
FF	571
DSP	12
BRAM	0
SRL	0

Table 61: HLS Solution 7 with column Index, values and x partitioning Export RTL Resource Usage

Timing	VHDL
CP required	10.000
CP achieved post-synthesis	7.449
CP achieved post-implementation	7.974

Table 62: HLS Solution 7 with columnIndex, values and x partitioning Export RTL Final Timing

Anche se le problematiche precedentemente citate sono state risolte, si potrebbe pensare di adottare un approccio differente così da cercare di ottenere una diminuzione delle risorse. In particolare, si potrebbero non considerare i tre partizionamenti all'interno del loop2 e aggiungere, invece, la direttiva di pipelining all'interno del loop1.

```
#include "definitions.h"

void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE x[size]) {

loop1: for (int i=0; i<rows; i++) {
    #pragma HLS pipeline
    DTYPE ytmp = 0;

loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {
    #pragma HLS loop_tripcount min=0 max=4 avg=2
    #pragma HLS pipeline</pre>
```

```
#pragma HLS unroll factor=4

ytmp += values[k] * x[columnIndex[k]];

y[i] = ytmp;

}

}
```

Effettuando la sintesi, si possono evidenziare i seguenti log nella console e i seguenti report.

WARNING: [XFORM 203-503] Ignored partial unroll directive for loop 'loop2' (smvmProject/smvm.cpp:21) because its parent loop or function is pipelined.

WARNING: [XFORM 203-503] Cannot unroll loop 'loop2' (smvmProject/smvm.cpp:21) in function 'smvm' completely: variable loop bound.

WARNING: [SCHED 204-65] Unable to satisfy pipeline directive: Loop contains subloop(s) not being unrolled or flattened.

In particolare, si può notare come il primo warning segnali, tramite console, che la direttiva di unroll all'interno del loop2 è stata ignorata dal momento che all'interno del parent loop, cioè il loop1, è presente una direttiva di pipeline. Invece, per quanto riguarda il secondo warning, segnala che il tool non riesce a soddisfare la direttiva di pipeline senza però specificare quale loop. Nello specifico, lo si può capire dal report di sintesi generato. Infatti, si può notare come non sia stata attuata la direttiva di pipeline nel loop1 dal momento che l'Initiation Interval associato risulta essere non definito. Inoltre, si può evidenziare come il trip count associato al loop2 sia pari a 4, cioè questo valore dimostra che effettivamente la direttiva di unrolling di fattore pari a 4 non è stata attuata. Tanto è vero che, altrimenti, si troverebbe un numero di iterazioni pari a 1 come precedentemente mostrato. In particolare, questo approccio del tool è dovuto al fatto che non riesce ad effettuare il pipeline del loop1 dal momento che non ci sono bound al loop in questione, cioè il tutto corrisponderebbe ad un'architettura che non è nota perchè i bound non sono noti.

Pertanto, è come se il tool riconducesse la soluzione hardware implementata ad una solution dove nel loop1 non è presente alcun pragma e nel loop2 sono presenti soltanto le direttive di trip count e pipeline. Praticamente è come se riconducesse il tutto alla solution 2.

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	10.208	1.25

Table 63: HLS Solution 7 with loop1 pipelined Timing Summary (ns)

Late	ency	Interval		
min	max	min	max	
17	45	17	45	

Table 64: HLS Solution 7 with loop1 pipelined Latency Summary (clock cycles)

Loop	Latency		Iteration Latency	Initiation Interval		Trip Count
Name	min	max		achieved	target	
- loop1	16	44	4~11	-	-	4
+ loop2	0	7	5	1	1	0~4

Table 65: HLS Solution 7 with loop1 pipelined Latency Loops Summary

Name	BRAM_18K	DSP48E	\mathbf{FF}	LUT
DSP	-	-	-	-
Expression	-	3	0	141
FIFO	-	-	-	-
Instance	-	-	_	-
Memory	0	-	_	-
Multiplexer	-	-	_	78
Register	-	-	340	32
Total	0	3	340	251
Available	280	220	106400	53200
Utilization (%)	0	1	~0	~0

Table 66: HLS Solution 7 with loop1 pipelined Utilization Estimates Summary

Infatti, si può notare come la latenza e l'utilizzazione delle risorse associate alla solution in questione risultano essere le medesime di quelle ottenute in corrispondenza della soluzione hardware 2.

RTL	Status	Latency		I	nterva	al	
		\min	avg	max	min	avg	max
VHDL	Pass	38	38	38	NA	NA	NA

Table 67: HLS Solution 7 with loop1 pipelined C/RTL Cosimulation Summary

Resource	VHDL
SLICE	38
LUT	115
FF	139
DSP	3
BRAM	0
SRL	0

TimingVHDLCP required10.000CP achieved post-synthesis5.745CP achieved post-implementation5.718

Table 68: HLS Solution 7 with loop1 pipelined Export RTL Resource Usage

Table 69: HLS Solution 7 with loop1 pipelined Export RTL Final Timing

Pertanto, confrontando le due soluzioni hardware implementate, rispettivamente quella associata all'unrolling di fattore 4 del loop2 e del partizionamento dei tre array e quella appena descritta, è possibile fare alcune considerazioni. In particolare, se l'obiettivo dell'ottimizzazione è quello di ottenere un parallelismo del loop2, nello specifico di un fattore pari a 4, allora l'unica implementazione possibile è quella ottenuta tramite partitioning dei tre array (columnIndex, values e x). Ovviamente, come precedentemente citato, tale soluzione presenta un'utilizzazione delle risorse maggiore rispetto alle altre solution presentate dal momento che viene effettuato un partizionamento di fattore 4 su tre array. Invece, se l'obiettivo è quello di ottenere una minore utilizzazione delle risorse, allora la solution si riconduce a quella ottenuta in corrispondenza della soluzione hardware 2 dal momento che i risultati ottenuti sono i medesimi. Bisogna specificare, però, che l'obiettivo della solution in questione, cioè la 7, è quella di poter ottenere un unrolling di fattore pari a 4 in corrispondenza del loop2 e, pertanto, la soluzione hardware ottimale corrisponde a quella ottenuta tramite partizionamento dei tre array.

5.8 Solution 8

Nella soluzione hardware in questione verrà utilizzata la direttiva di pipeline, di unrolling di fattore pari a 2 e la direttiva di partizionamento di tipologia cyclic. Nello specifico, verranno analizzate le seguenti implementazioni relative al loop2:

- Pipeline, Unroll=2, Cyclic=4 (columnIndex, values, x)
- Pipeline, Unroll=2, Cyclic=4 (columnIndex)
- Pipeline, Unroll=2, Cyclic=4 (values)
- Pipeline, Unroll=2, Cyclic=4 (x)

In particolare, è possibile evidenziare nel dettaglio le differenti soluzioni hardware nei seguenti allegati.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=2
9
        #pragma HLS array_partition variable=columnIndex cyclic factor=4
        #pragma HLS array_partition variable=values cyclic factor=4
11
        #pragma HLS array_partition variable=x cyclic factor=4
12
13
        ytmp += values[k] * x[columnIndex[k]];
14
15
      y[i] = ytmp;
    }
16
17 }
```

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=2
        #pragma HLS array_partition variable=columnIndex cyclic factor=4
        ytmp += values[k] * x[columnIndex[k]];
11
12
      y[i] = ytmp;
13
14
15 }
```

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
5
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=2
9
        #pragma HLS array_partition variable=values cyclic factor=4
10
11
        ytmp += values[k] * x[columnIndex[k]];
12
      y[i] = ytmp;
    }
14
15 }
```

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {
      DTYPE ytmp = 0;
5
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
         #pragma HLS loop_tripcount min=0 max=4 avg=2
         #pragma HLS pipeline
        #pragma HLS unroll factor=2
9
        #pragma HLS array_partition variable=x cyclic factor=4
10
         ytmp += values[k] * x[columnIndex[k]];
12
13
      y[i] = ytmp;
14
15
```

Effettuando la sintesi è possibile evidenziare il seguente report:

Solution	Clock	Target	Estimated	Uncertainty
columnIndex, values, x	ap_clk	10.00	8.510	1.25
columnIndex	ap_clk	10.00	8.510	1.25
values	ap_clk	10.00	8.510	1.25
X	ap_clk	10.00	8.510	1.25

Table 70: HLS Solution 8 Timing Summary (ns)

Solution	Late	ency	Interval		
	min	max	min	max	
columnIndex, values, x	29	37	29	37	
columnIndex	33	41	33	41	
values	33	41	33	41	
X	29	37	29	37	

Table 71: HLS Solution 8 Latency Summary (clock cycles)

Si può notare come i valori di latenza totale, delle latenze totali dei loop corrispondenti e di Iteration Latency risultano essere differenti tra le varia solution. In particolare, la soluzione che implementa il partizionamento dei tre array (columnIndex, values e x) presenta valori di latenza uguali a quelli della soluzione che implementa il partizionamento dell'array x. Bisogna notare, però, che il valore del trip count risulta essere il medesimo per ogni solution. In particolare, essendo previsto un unrolling di fattore pari a 2 all'interno del loop2, il corrispondente valore risulta essere dimezzato rispetto alla solution 1 in cui non è presente alcun pragma di parallelismo. Nello specifico, considerando la solution 6 dove era stata considerata un'architettura similare ma prevedendo una direttiva di partizionamento di fattore pari a 2, i valori di latency e di Iteration Latency associati alla soluzione con partizionamento dei tre array e quelli associati alla soluzione con partizionamento dell'array x, risultano essere diminuiti. Infatti, nella solution 6, per il partizionamento dei tre array e per il partizionamento di x, erano previsti per entrambi una latency min pari a 32 e max pari a 40 mentre un'iteration latency pari a 8~10. Nella soluzione hardware in questione, cioè la 8, e per i partizionamenti corrispondenti si hanno rispettivamente una latency min pari a 28 e max pari a 40 mentre un'iteration latency pari a 7~9. Nello specifico, considerando un partitioning di fattore pari a 4, evidentemente il tool è riuscito ad effettuare ottimizzazioni dal punto di vista della latenza così da giustificare una diminuzione delle latency stimate.

Solution	Loop Name	Late	ency	Iteration Latency	Initiation	n Interval	Trip
		min	max		achieved	target	Count
columnIndex, values, x	- loop1	28	36	7~9	-	-	4
	+ loop2	3	5	4	1	1	0~2
columnIndex	- loop1	32	40	8~10	-	-	4
	+ loop2	4	6	5	1	1	0~2
values	- loop1	32	40	8~10	-	-	4
	+ loop2	4	6	5	1	1	0~2
X	- loop1	28	36	7~9	-	-	4
	+ loop2	3	5	4	1	1	$0 \sim 2$

Table 72: HLS Solution 8 Latency Loops Summary

Solution	${ m BRAM_18K}$	DSP48E	\mathbf{FF}	LUT
columnIndex, values, x	0	6	630	628
columnIndex	0	6	535	560
values	0	6	634	581
X	0	6	596	441

Table 73: HLS Solution 8 Utilization Estimates [#]

Solution	RTL	Status	Latency		Interval			
			min avg max		min	avg	max	
columnIndex, values, x	VHDL	Pass	33	33	33	NA	NA	NA
columnIndex	VHDL	Pass	37	37	37	NA	NA	NA
values	VHDL	Pass	37	37	37	NA	NA	NA
X	VHDL	Pass	33	33	33	NA	NA	NA

Table 74: HLS Solution 8 C/RTL Cosimulation Report

Si può notare come la maggiore utilizzazione delle risorse si ha in corrrispondenza della soluzione hardware basata sul partizionamento dei tre array dove si ha la maggiore utilizzazione di slice, LUT e FF. Inoltre, si può evidenziare che le soluzioni basate rispettivamente sul partitioning di columnIndex e values risultano avere pressoché la medesima utilizzazione dal momento che le dimensioni di tali strutture dati è la medesima. In particolare, rispetto alla soluzione hardware similare dove era stato utilizzato un fattore di partitioning pari a 2, si può notare, in corrispondenza del partizionamento dei tre array, un incremento dei FF di circa il 59%, un incremento delle LUT e delle slice di circa il 9%.

Solution	SLICE	LUT	FF	DSP	BRAM	CP	CP	CP
						required	achieved	achieved
							post-	post-
							synthesis	implementation
columnIndex, values, x	123	343	315	6	0	10	6.540	6.571
columnIndex	85	261	226	6	0	10	7.496	7.654
values	92	274	196	6	0	10	7.927	7.780
X	104	248	313	6	0	10	6.540	6.844

Table 75: HLS Solution 8 Export RTL Report

5.9 Solution 9

Qui, di seguito, viene riportata l'architettura relativa alla nona solution.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
         #pragma HLS loop_tripcount min=0 max=4 avg=2
         #pragma HLS pipeline
         #pragma HLS unroll factor=8
9
         ytmp += values[k] * x[columnIndex[k]];
11
      y[i] = ytmp;
12
    }
13
14 }
```

In particolare, rispetto alla soluzione hardware 5 e 7 dove rispettivamente era stato considerato un parallelismo di fattore pari a 2 e un parallelismo di fattore pari a 4, in questa solution è stato considerato un unrolling di fattore pari a 8. In particolare, ciò che ci si aspetta è un aumento delle risorse ed eventuali problematiche relative al timing, similari a quelle riscontrate nella solution 7, dal momento che il tool deve gestire all'interno del loop2 più accessi in memoria paralleli.

Effettuando la sintesi è possibile evidenziare il seguente log nella console:

WARNING: [SCHED 204-69] Unable to schedule 'load' operation ('columnIndex_load_6', smvmProject/s-mvm.cpp:34) on array 'columnIndex' due to limited memory ports. Please consider using a memory core with more ports or partitioning the array 'columnIndex'.

Tale log sta a significare che non riesce a schedulare correttamente, dal punto di vista degli accessi in memoria, la load operation relativa all'array *columnIndex* dato dal numero limitato di porte relative alla memoria. In particolare, analizzando il report relativo alla sintesi, si può notare come l'Initiation Interval, associato al loop2, raggiunto risulta essere maggiore di quello target.

Clock	Target	Estimated	Uncertainty
ap_clk	10.00	8.510	1.25

Table 76:	HLS Solution	n 9 Timing	Summary	(ns)

Late	\mathbf{ency}	Inte	erval
\min	max	min	max
45	61	45	61

Table 77: HLS Solution 9 Latency Summary (clock cycles)

Loop	Latency		Iteration Latency	Initiation	n Interval	Trip Count
Name	min	max		achieved	target	
- loop1	44	60	11~15	-	-	4
+ loop2	7	11	8	4	1	0~1

Table 78: HLS Solution 9 Latency Loops Summary

Pertanto, si potrebbe aggiungere una direttiva di partizionamento con fattore pari a 8 relativa all'array menzionato all'interno del log, cioè *columnIndex*.

```
#include "definitions.h"

void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
    x[size]) {

loop1: for (int i=0; i<rows; i++) {

DTYPE ytmp = 0;

loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {

#pragma HLS loop_tripcount min=0 max=4 avg=2</pre>
```

```
#pragma HLS pipeline
#pragma HLS unroll factor=8
#pragma HLS array_partition variable=columnIndex cyclic factor=4
ytmp += values[k] * x[columnIndex[k]];

y[i] = ytmp;

y[i] = ytmp;
}
```

Effettuando nuovamente la sintesi, si ottiene il seguente log nella console e i seguenti valori di latenza. WARNING: [SCHED 204-69] Unable to schedule 'load' operation ('values_load_6', smvmProject/smvm.cpp:34) on array 'values' due to limited memory ports. Please consider using a memory core with more ports or partitioning the array 'values'.

Loop	Latency		Iteration Latency	Initiation	n Interval	Trip Count
Name	min	max		achieved	target	
- loop1	44	60	11~15	-	-	4
+ loop2	7	11	8	4	1	0~1

Table 79: HLS Solution 9 with columnIndex partitioning Latency Loops Summary

Si può notare come in questo caso il warning sia relativo all'array *values*. In particolare, la tipologia di warning è la medesima facendo presupporre che il tool non riesca a schedulare correttamente, secondo le direttive imposte dall'architetture, gli accessi in parallello all'array *values*. Infatti, il valore di Iteration Latency raggiunto risulta essere ancora maggiore di quello di quello target.

Pertanto, si potrebbe aggiungere una direttiva di partizionamento relativa all'array menzionato all'interno del log, cioè values.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
         #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
9
        #pragma HLS unroll factor=8
        #pragma HLS array_partition variable=columnIndex cyclic factor=4
        #pragma HLS array_partition variable=values cyclic factor=4
11
        ytmp += values[k] * x[columnIndex[k]];
13
14
      y[i] = ytmp;
    }
15
```

Effettuando nuovamente la sintesi, si ottiene il seguente log nella console e i seguenti valori di latenza. WARNING: [SCHED 204-69] Unable to schedule 'load' operation ('x_load_6', smvmProject/smvm.cpp:34) on array 'x' due to limited memory ports. Please consider using a memory core with more ports or partitioning the array 'x'.

Loop	Latency		Iteration Latency	Initiation Interval		Trip Count
Name	min	max		achieved	target	
- loop1	44	60	11~15	-	-	4
+ loop2	7	11	8	4	1	0~1

Table 80: HLS Solution 9 with columnIndex and values partitioning Latency Loops Summary

Si può notare come in questo caso il warning sia relativo all'array x. In particolare, la tipologia di warning è la medesima della precedente. Anche in questo caso il valore di Iteration Latency raggiunto risulta essere

ancora maggiore di quello di quello target.

Pertanto, si potrebbe aggiungere una direttiva di partizionamento relativa all'array menzionato all'interno del \log , cioè x.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=8
9
        #pragma HLS array_partition variable=columnIndex cyclic factor=4
        #pragma HLS array_partition variable=values cyclic factor=4
        #pragma HLS array_partition variable=x cyclic factor=4
13
        ytmp += values[k] * x[columnIndex[k]];
14
      y[i] = ytmp;
    }
16
17 }
```

Effettuando nuovamente la sintesi, si ottiene il seguente log nella console e il seguente report.

WARNING: [SCHED 204-68] The II Violation in module 'smvm': Unable to enforce a carried dependence constraint (II = 1, distance = 1, offset = 0) between 'add' operation ('ytmp_1_7', smvmProject/smvm.cpp:34) and 'add' operation ('ytmp_1', smvmProject/smvm.cpp:34).

WARNING: [SCHED 204-68] The II Violation in module 'smvm': Unable to enforce a carried dependence constraint (II = 1, distance = 1, offset = 1) between 'add' operation ('ytmp_1_5', smvmProject/smvm.cpp:34) and 'add' operation ('ytmp_1_2', smvmProject/smvm.cpp:34).

WARNING: [SCHED 204-68] The II Violation in module 'smvm': Unable to enforce a carried dependence constraint (II = 2, distance = 1, offset = 1) between 'add' operation ('ytmp_1_6', smvmProject/smvm.cpp:34) and 'add' operation ('ytmp_1_2', smvmProject/smvm.cpp:34).

In particolare, tali warning suggeriscono problematiche relative alla variabile ytmp. Nello specifico, ymtp è una variabile temporanea (di appoggio) di tipo DTYPE, cioè int, e pertanto il partizionamento su tale variabile non avrebbe senso poiché quest'ultimo funziona solo con gli array. Bisogna notare però che il problema non è relativo a ytmp ma è associato a y, cioè l'output, che è un vettore. Inoltre, y fa riferimento al loop1 e questo suggerisce che gli eventuali problemi sono relativi al ciclo1 ed, essendo che il loop1 presenta al suo interno il loop2, allora tali problemi si ripercuotono sul loop2. In aggiunta, si evidenzia come in questo caso l'Initiation Interval raggiunto risulta essere decrementato da 4 a 3 ma comunque ancora maggiore di quello target.

	Loop	Latency		Iteration Latency	Initiation	ı Interval	Trip Count
	Name	min	max		achieved	target	
Ī	- loop1	40	52	10~13	-	-	4
	+ loop2	6	9	7	3	1	0~1

Table 81: HLS Solution 9 with columnIndex, values and x partitioning Latency Loops Summary

Un'idea potrebbe quella di effettuare un partizionamento anche sull'array rowPtr.

```
#include "definitions.h"

void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
    x[size]) {

loop1: for (int i=0; i<rows; i++) {
    DTYPE ytmp = 0;
    loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {
    #pragma HLS loop_tripcount min=0 max=4 avg=2
    #pragma HLS pipeline</pre>
```

```
#pragma HLS unroll factor=8
9
        #pragma HLS array_partition variable=columnIndex cyclic factor=4
        #pragma HLS array_partition variable=values cyclic factor=4
11
12
        #pragma HLS array_partition variable=x cyclic factor=4
        #pragma HLS array_partition variable=rowPtr cyclic factor=4
        ytmp += values[k] * x[columnIndex[k]];
14
15
      y[i] = ytmp;
16
    }
17
18 }
```

Effettuando nuovamente la sintesi, si ottiene il seguente log nella console e il seguente report.

WARNING: [SCHED 204-68] The II Violation in module 'smvm': Unable to enforce a carried dependence constraint (II = 1, distance = 1, offset = 0) between 'add' operation ('ytmp_1-7', smvmProject/smvm.cpp:34) and 'add' operation ('ytmp_1', smvmProject/smvm.cpp:34).

WARNING: [SCHED 204-68] The II Violation in module 'smvm': Unable to enforce a carried dependence constraint (II = 1, distance = 1, offset = 1) between 'add' operation ('ytmp_1_5', smvmProject/smvm.cpp:34) and 'add' operation ('ytmp_1_2', smvmProject/smvm.cpp:34).

WARNING: [SCHED 204-68] The II Violation in module 'smvm': Unable to enforce a carried dependence constraint (II = 2, distance = 1, offset = 1) between 'add' operation ('ytmp_1_6', smvmProject/smvm.cpp:34) and 'add' operation ('ytmp_1_2', smvmProject/smvm.cpp:34).

In particolare, si riscontrano i medesimi warning allegati precedentemente.

Loop	Latency		Iteration Latency	Initiation	n Interval	Trip Count
Name	min max			achieved	target	
- loop1	44 56		11~14	-	-	4
+ loop2	6 9		7	3	1	0~1

Table 82: HLS Solution 9 with columnIndex, values, x and rowPtr partitioning Latency Loops Summary

Pertanto, a tale proposito si potrebbe effettuare un partizionamento anche su v.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
3
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=8
9
        #pragma HLS array_partition variable=columnIndex cyclic factor=4
        #pragma HLS array_partition variable=values cyclic factor=4
11
        #pragma HLS array_partition variable=x cyclic factor=4
        #pragma HLS array_partition variable=rowPtr cyclic factor=4
        #pragma HLS array_partition variable=y cyclic factor=4
14
        ytmp += values[k] * x[columnIndex[k]];
      }
16
      y[i] = ytmp;
17
    }
18
19 }
```

Effettuando nuovamente la sintesi, si ottiene il seguente log nella console e il seguente report.

WARNING: [SCHED 204-68] The II Violation in module 'smvm': Unable to enforce a carried dependence constraint (II = 1, distance = 1, offset = 0) between 'add' operation ('ytmp_1-7', smvmProject/smvm.cpp:35) and 'add' operation ('ytmp_1', smvmProject/smvm.cpp:35).

WARNING: [SCHED 204-68] The II Violation in module 'smvm': Unable to enforce a carried dependence constraint (II = 1, distance = 1, offset = 1) between 'add' operation ('ytmp_1_5', smvmProject/smvm.cpp:35) and 'add' operation ('ytmp_1_2', smvmProject/smvm.cpp:35).

WARNING: [SCHED 204-68] The II Violation in module 'smvm': Unable to enforce a carried dependence constraint (II = 2, distance = 1, offset = 1) between 'add' operation ('ytmp_1_6', smvmProject/smvm.cpp:35)

and 'add' operation ('ytmp_1_2', smvmProject/smvm.cpp:35).

Nello specifico, si riscontrano nuovamente i medesimi warning allegati precedentemente.

Loop	Latency		Iteration Latency	Initiation	n Interval	Trip Count
Name	min	max		achieved	target	
- loop1	44	56	11~14	-	-	4
+ loop2	6	9	7	3	1	0~1

Table 83: HLS Solution 9 with columnIndex, values, x, rowPtr and y partitioning Latency Loops Summary

Pertanto, dal momento che i warning sono ancora presenti e il valore di Initiation Latency non tende a diminuire, si potrebbe provare effettuando anche il pipelining del loop1.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      #pragma HLS pipeline
      DTYPE ytmp = 0;
6
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
         #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=8
        #pragma HLS array_partition variable=columnIndex cyclic factor=4
11
        #pragma HLS array_partition variable=values cyclic factor=4
        #pragma HLS array_partition variable=x cyclic factor=4
13
        ytmp += values[k] * x[columnIndex[k]];
14
      y[i] = ytmp;
16
    }
17
18 }
```

Effettuando nuovamente la sintesi, si ottiene il seguente log nella console e il seguente report.

WARNING: [XFORM 203-503] Ignored partial unroll directive for loop 'loop2' (smvmProject/smvm.cpp:21) because its parent loop or function is pipelined.

WARNING: [XFORM 203-503] Cannot unroll loop 'loop2' (smvmProject/smvm.cpp:21) in function 'smvm' completely: variable loop bound.

WARNING: [SCHED 204-65] Unable to satisfy pipeline directive: Loop contains subloop(s) not being unrolled or flattened.

Loop	Late	ency	Iteration Latency	Initiation	n Interval	Trip Count
Name	min	max		achieved	target	
- loop1	16	40	4~10	-	-	4
+ loop2	0	6	4	1	1	0~4

Table 84: HLS Solution 9 with columnIndex, values and x partitioning and loop1 pipelined Latency Loops Summary

Si può notare come i warning relativi a ytmp non sono più presenti all'interno della console e che, inoltre, l'Initiation Interval relativo al loop2 presenta un valore raggiunto uguale a quello target, cioè pari a 1. In aggiunta, si possono evidenziare ulteriori warning all'interno della console. Essi sono i medesimi di quelli riscontrati nella solution 7, in cui veniva effettuato un unrolling di fattore pari a 4 nel loop2, dopo aver applicato il pipeline al loop1. Anche in questo caso, il tool non è riuscito a soddisfare la richiesta di pipeline a causa dei bound non noti e, pertanto, non riuscendo nemmeno a soddisfare la direttiva di unrolling all'interno del loop2. Infatti, si può notare come i valori di Initiation Interval (achieved e target) risultano essere non definiti, mentre il trip count relativo relativo al loop2 risulta essere il medesimo di quello della solution2 dove non era presente alcun pragma di parallelismo nel ciclo 2.

Pertanto, considerando l'implementazione finale ottenuta in corrispondenza della solution in questione, si effettua la C/RTL Cosimulation e l'Export RTL e si analizzano, di conseguenza, i report corrispondenti.

	RTL	Status	Latency			Interval			
			min	avg	max	min	avg	max	
Ì	VHDL	Pass	34	34	34	NA	NA	NA	

Table 85: HLS Solution 9 with column Index, values and x partitioning and loop1 pipelined C/RTL Cosimulation Summary

Resource	VHDL
SLICE	80
LUT	208
FF	263
DSP	3
BRAM	0
SRL	0

Table 86: HLS Solution 9 with column Index, values and x partitioning and loop1 pipelined Export RTL Resource Usage

Timing	VHDL
CP required	10.000
CP achieved post-synthesis	5.745
CP achieved post-implementation	5.762

Table 87: HLS Solution 9 with column Index, values and x partitioning and loop1 pipelined Export RTL Final Timing

5.10 Solution 10

Nella soluzione hardware in questione verrà utilizzata la direttiva di pipeline, di unrolling di fattore pari a 2 e la direttiva di partizionamento di tipologia cyclic. Nello specifico, verranno analizzate le seguenti implementazioni relative al loop2:

- Pipeline, Unroll=2, Cyclic=8 (columnIndex, values, x)
- Pipeline, Unroll=2, Cyclic=8 (columnIndex)
- Pipeline, Unroll=2, Cyclic=8 (values)
- Pipeline, Unroll=2, Cyclic=8 (x)

In particolare, è possibile evidenziare nel dettaglio le differenti soluzioni hardware nei seguenti allegati.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=2
9
        #pragma HLS array_partition variable=columnIndex cyclic factor=8
        #pragma HLS array_partition variable=values cyclic factor=8
11
        #pragma HLS array_partition variable=x cyclic factor=8
12
13
        ytmp += values[k] * x[columnIndex[k]];
14
15
      y[i] = ytmp;
    }
16
17 }
```

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=2
        #pragma HLS array_partition variable=columnIndex cyclic factor=8
        ytmp += values[k] * x[columnIndex[k]];
11
12
      y[i] = ytmp;
13
14
15 }
```

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
5
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=2
9
        #pragma HLS array_partition variable=values cyclic factor=8
10
11
        ytmp += values[k] * x[columnIndex[k]];
12
      y[i] = ytmp;
    }
14
```

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
        #pragma HLS loop_tripcount min=0 max=4 avg=2
        #pragma HLS pipeline
        #pragma HLS unroll factor=2
9
10
        #pragma HLS array_partition variable=x cyclic factor=8
        ytmp += values[k] * x[columnIndex[k]];
11
13
      y[i] = ytmp;
14
```

Effettuando la sintesi si ottiene il seguente log.

ERROR: [XFORM 203-103] Cannot partition array 'x' (smvmProject/smvm.cpp:11): incorrect partition factor 8.

In particolare, la console sta segnalando che effettivamente non riesce a partizionare l'array x dal momento che la dimensione dell'array risulta essere non compatibile con il fattore di partitioning dichiarato. Infatti, la dimensione di x inizialmente dichiarata in definitions.h è pari a 4 mentre il fattore di partizionamento che si sta utilizzando è pari a 8. A questo proposito si potrebbe modificare il valore di dimensionamento relativo a x all'interno dell'header. In particolare è necessario modificare sia il valore di size sia il valore di rows poiché l'applicazione che si sta implementando richiede che la matrice sia quadrata. Inoltre, bisogna anche modificare i parametri dichiarati all'interno della direttiva trip count dal momento che il numero di righe e, quindi, di iterazioni risulta essere differente.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=8 avg=4
        #pragma HLS pipeline
9
        #pragma HLS unroll factor=2
10
        #pragma HLS array_partition variable=columnIndex cyclic factor=8
        #pragma HLS array_partition variable=values cyclic factor=8
11
        #pragma HLS array_partition variable=x cyclic factor=8
        ytmp += values[k] * x[columnIndex[k]];
13
```

```
y[i] = ytmp;
16 }
17 }
#include "definitions.h"
3 void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=8 avg=4
8
        #pragma HLS pipeline
9
        #pragma HLS unroll factor=2
        #pragma HLS array_partition variable=columnIndex cyclic factor=8
11
        ytmp += values[k] * x[columnIndex[k]];
12
13
      y[i] = ytmp;
14
15 }
#include "definitions.h"
3 void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
        #pragma HLS loop_tripcount min=0 max=8 avg=4
        #pragma HLS pipeline
8
        #pragma HLS unroll factor=2
9
        #pragma HLS array_partition variable=values cyclic factor=8
10
11
        ytmp += values[k] * x[columnIndex[k]];
      }
12
13
      y[i] = ytmp;
14
15 }
#include "definitions.h"
3 void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
        #pragma HLS loop_tripcount min=0 max=8 avg=4
        #pragma HLS pipeline
8
        #pragma HLS unroll factor=2
9
        #pragma HLS array_partition variable=x cyclic factor=8
10
11
        ytmp += values[k] * x[columnIndex[k]];
12
13
      y[i] = ytmp;
    }
14
15 }
```

Pertanto, effettuando la sintesi si ottiene il seguente report.

Solution	Clock	Target	Estimated	Uncertainty
columnIndex, values, x	ap_clk	10.00	8.510	1.25
columnIndex	ap_clk	10.00	8.510	1.25
values	ap_clk	10.00	8.510	1.25
X	ap_clk	10.00	8.510	1.25

Table 88: HLS Solution 10 Timing Summary (ns)

Solution	Late	ency	Interval		
	min	max	min	max	
columnIndex, values, x	57	89	57	89	
columnIndex	65	97	65	97	
values	65	97	65	97	
X	57	89	57	89	

Table 89: HLS Solution 10 Latency Summary (clock cycles)

Solution	Loop Name	Late	ency	Iteration Latency	Initiation	n Interval	Trip
		min	max		achieved	target	Count
columnIndex, values, x	- loop1	56	88	7~11	-	-	8
	+ loop2	3	7	4	1	1	0~4
columnIndex	- loop1	64	96	8~12	-	-	8
	+ loop2	4	8	5	1	1	0~4
values	- loop1	64	96	8~12	-	-	8
	+ loop2	4	8	5	1	1	0~4
x	- loop1	56	88	7~11	-	-	8
	+ loop2	3	7	4	1	1	0~4

Table 90: HLS Solution 10 Latency Loops Summary

Solution	${ m BRAM_18K}$	DSP48E	FF	LUT
columnIndex, values, x	0	6	762	900
columnIndex	0	6	539	752
values	0	6	640	773
X	0	6	727	492

Table 91: HLS Solution 10 Utilization Estimates [#]

In particolare, dall'interfaccia Analysis sotto allegata (corrispondente al partitioning dell'array x), si può notare come l'unrolling di fattore 2 sia stato applicato correttamente dal momento che vengono effettuate 2 operazioni di moltiplicazione e 2 operazioni di somma in un'unica iterazione del loop2. Nello specifico, si può evidenziare come i prodotti richiedano l'utilizzo di 3 DSP ognuno tale da giustificare l'utilizzazione di tali risorse pari a 6 come riportato nel report di sintesi. Inoltre, si può notare come il partitioning di fattore pari a 8 abbia effettuato il partizionamento dell'array x in 8 sub-array. In particolare, ogni sub-array prevede un'utilizzazione di bit pari a 32 e una corrispondente utilizzazione dei FF pari a 32 ognuno. Questo aspetto è di fondamentale importanza poiché dal momento che l'array x presenta dimensione pari a 8 e dal momento che il fattore di partizionamento è pari a 8, questo vuol dire che il tool ha effettuato un partitioning di tipo cyclic corrispondente ad un partitioning di tipo complete, cioè il risultato sono dei sub-array di dimensione pari a 1 (poiché la dimensione di x coincide con il fattore di partizionamento). Tanto è vero che effettuando l'array partitioning di tipologia complete sul solo array x, si avrebbe la stessa utilizzazione di risorse e, soprattutto, l'interfaccia Analysis e Resource Profile corrisponderebbero a quelle sotto allegate. Infatti, bisogna ricordare che l'array partitioning di tipologia complete comporta che l'array venga suddiviso in singoli registri mentre quello di tipologia cyclic comporta che vengano creati blocchi ciclici di uguali dimensioni interlacciando gli elementi dell'array iniziale. Pertanto, ciò che cambia tra le due tipologie è che il secondo vada ad assegnare in questi sub-array in maniera ciclica gli elementi dell'array iniziale in base al fattore scelto. Però, nel caso in cui tale fattore corrisponde alla dimensione dell'array iniziale, nel momento in cui il tool assegna l'ultimo elemento ad un sub-array (dopodiché dovrebbe assegnare il prossimo elemento se presente nell'array, ma non in questo caso, al primo sub-array e così via) terminando la procedura di partitioning e lasciando in ogni sub-array un solo elemento. Questo sostanzialmente corrisponderebbe ad avere 8 registri a 32 bit ognuno come succederebbe nella tipologia complete. Invece, per quanto riguarda gli array columnIndex e values, dal momento che presentano dimensione differente rispetto al fattore di partizionamento, questo si traduce in differenti scheduling e performance.




Figure 8: HLS Solution 10 Analysis

Solution	RTL	Status	Latency		Interval			
			min	avg	max	min	avg	max
columnIndex, values, x	VHDL	Pass	61	61	61	NA	NA	NA
columnIndex	VHDL	Pass	69	69	69	NA	NA	NA
values	VHDL	Pass	69	69	69	NA	NA	NA
X	VHDL	Pass	61	61	61	NA	NA	NA

Table 92: HLS Solution 10 C/RTL Cosimulation Report

Si può notare come l'utilizzazione delle risorse sia aumentata rispetto alle soluzioni 6 (loop2 Pipeline, Unroll=2, Cyclic=2) e 8 (loop2 Pipeline, Unroll=2, Cyclic=4). In particolare, considerando le soluzioni hardware corrispondenti al partizionamento di tutti e tre gli array, si evidenzia rispettivamente un aumento di circa il 66% in corrispondenza delle slice rispetto alla soluzione 6 e 8, un aumento di circa il 77% e di circa il 63% in corrispondenza delle LUT, un aumento di circa il 127% e di circa il 43%.

Per quanto riguarda le soluzioni hardware corrispondenti al partizionamento di columnIndex, rispetto alla soluzione 6 e 8, si registra rispettivamente un aumento di un'unità e una diminuzione di 2 slice, un aumento di nove unità e di 7 unità delle LUT, un aumento di 6 unità e di 4 unità dei FF.

Per quanto riguarda le solution corrispondenti al partitioning di values, rispetto alla soluzione 6 e 8, si registra rispettivamente un aumento di circa il 18% e di circa il 27% delle slice, un aumento di 15 unità e di circa il 25% delle LUT, un aumento di 25 unità e di 3 unità dei FF.

Per quanto riguarda le soluzioni hardware corrispondenti al partizionamento di x, rispetto alla soluzione 6 e 8, si registra rispettivamente un aumento di circa il 44% e di circa il 38% delle slice, un aumento di circa il 24% e di circa il 25% delle LUT, un aumento di circa il 124% e di circa il 42% dei FF.

Solution	SLICE	LUT	\mathbf{FF}	DSP	BRAM	CP	CP	CP
						required	achieved	achieved
							post-	post-
							synthesis	implementation
columnIndex, values, x	204	558	449	6	0	10	6.540	6.840
columnIndex	83	268	230	6	0	10	7.496	8.115
values	117	342	199	6	0	10	7.927	7.603
X	143	311	444	6	0	10	6.540	6.790

Table 93: HLS Solution 10 Export RTL Report

Ovviamente questo aumento di utilizzazione delle risorse è dovuto all'incremento del fattore di partizionamento adottato nelle soluzioni hardware. Infatti, si evidenzia che il maggiore incremento delle risorse si ha rispetto alla soluzione 6 dove era previsto un fattore pari a 2 rispetto alla soluzione in questione dove il fattore di partitioning previsto è stato di 8.

5.11 Solution 11

Considerando il codice utilizzato nella precedente solution, nella soluzione hardware in questione verrà utilizzata la direttiva di pipeline, di unrolling di fattore pari a 2 e la direttiva di partizionamento di tipologia block. Nello specifico, verranno analizzate le seguenti implementazioni relative al loop2:

- Pipeline, Unroll=2, Block=8 (columnIndex, values, x)
- Pipeline, Unroll=2, Block=8 (columnIndex)
- Pipeline, Unroll=2, Block=8 (values)
- Pipeline, Unroll=2, Block=8 (x)

In particolare, è possibile evidenziare nel dettaglio le differenti soluzioni hardware nei seguenti allegati.

```
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=8 avg=4
        #pragma HLS pipeline
8
        #pragma HLS unroll factor=2
9
        #pragma HLS array_partition variable=columnIndex block factor=8
10
        #pragma HLS array_partition variable=values block factor=8
11
12
        #pragma HLS array_partition variable=x block factor=8
        ytmp += values[k] * x[columnIndex[k]];
13
14
      y[i] = ytmp;
15
16
17 }
```

```
#pragma HLS array_partition variable=columnIndex block factor=8
10
11
        ytmp += values[k] * x[columnIndex[k]];
12
13
      y[i] = ytmp;
    }
14
15 }
#include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
     x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
5
      DTYPE ytmp = 0;
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=8 avg=4
        #pragma HLS pipeline
        #pragma HLS unroll factor=2
9
10
        #pragma HLS array_partition variable=values block factor=8
11
        ytmp += values[k] * x[columnIndex[k]];
12
      y[i] = ytmp;
13
    }
14
15 }
  #include "definitions.h"
  void smvm(int rowPtr[rows+1], int columnIndex[nnz], DTYPE values[nnz], DTYPE y[size], DTYPE
      x[size]) {
    loop1: for (int i=0; i<rows; i++) {</pre>
      DTYPE ytmp = 0;
5
      loop2: for (int k=rowPtr[i]; k<rowPtr[i+1]; k++) {</pre>
6
        #pragma HLS loop_tripcount min=0 max=8 avg=4
        #pragma HLS pipeline
        #pragma HLS unroll factor=2
9
        #pragma HLS array_partition variable=x block factor=8
10
11
        ytmp += values[k] * x[columnIndex[k]];
12
      y[i] = ytmp;
13
```

Effettuando la sintesi si ottiene il seguente log.

14 }

WARNING: [XFORM 203-105] Cannot partition array 'columnIndex' (smvmProject/smvm.cpp:11): indivisible factor 8 on dimension 1, which has 9 elements.

WARNING: [XFORM 203-105] Cannot partition array 'values' (smvmProject/smvm.cpp:11): indivisible factor 8 on dimension 1, which has 9 elements.

In particolare, la console sta segnalando che il tool non riesce a partizionare correttamente, tramite la tipologia block e il fattore 8 dichiarato, gli array columnIndex e values dal momento che presentano un numero di elementi che risulta essere non multiplo del fattore di array partitioning dichiarato. Pertanto, a tale proposito si modifica, di conseguenza, la variabile nnz, cioè il numero di elementi non nulli all'interno della matrice, nell'header. Nello specifico è stato scelto un valore pari a 16. Pertanto, ciò che ci si aspetta è che il tool divida tali array, columnIndex e values, in 8 sub-array aventi ognuno 2 elementi. Invece, per quanto riguarda l'array x, avente dimensione pari a 8, ci si aspetta che il tool lo divida in 8 sub-array da un elemento ognuno.

```
12 const static int nnz = 16;
13
14    /**
15    * Number of Rows.
16    */
17    const static int rows = 8;
18
19    ...
20
21    #endif
```

Pertanto, effettuando la sintesi si ottiene il seguente report.

Solution	Clock	Target	Estimated	Uncertainty
columnIndex, values, x	ap_clk	10.00	8.510	1.25
columnIndex	ap_clk	10.00	8.510	1.25
values	ap_clk	10.00	8.510	1.25
X	ap_clk	10.00	8.510	1.25

Table 94: HLS Solution 11 Timing Summary (ns)

Solution	Late	ency	Interval		
	min	max	min	max	
columnIndex, values, x	57	89	57	89	
columnIndex	65	97	65	97	
values	65	97	65	97	
x	57	89	57	89	

Table 95: HLS Solution 11 Latency Summary (clock cycles)

Solution	Loop Name	Latency		Iteration Latency	Initiation	n Interval	Trip
		min	max		achieved	target	Count
columnIndex, values, x	- loop1	56	88	7~11	-	-	8
	+ loop2	3	7	4	1	1	$0 \sim 4$
columnIndex	- loop1	64	96	8~12	-	-	8
	+ loop2	4	8	5	1	1	0~4
values	- loop1	64	96	8~12	-	-	8
	+ loop2	4	8	5	1	1	0~4
X	- loop1	56	88	7~11	-	-	8
	+ loop2	3	7	4	1	1	$0 \sim 4$

Table 96: HLS Solution 11 Latency Loops Summary

Solution	BRAM_18K	DSP48E	FF	LUT
columnIndex, values, x	0	6	789	674
columnIndex	0	6	536	503
values	0	6	597	503
X	0	6	727	492

Table 97: HLS Solution 11 Utilization Estimates [#]

Solution	RTL	Status	Latency			Interval		
			min	avg	max	min	avg	max
columnIndex, values, x	VHDL	Pass	64	64	64	NA	NA	NA
columnIndex	VHDL	Pass	72	72	72	NA	NA	NA
values	VHDL	Pass	72	72	72	NA	NA	NA
x	VHDL	Pass	64	64	64	NA	NA	NA

Table 98: HLS Solution 11 C/RTL Cosimulation Report

Si può notare come, rispetto alla solution 10 dove era stato applicato un partitioning dello stesso fattore ma di tipologia cyclic, l'utilizzazione delle risorse in corrispondenza del solo partizionamento dell'array x non cambia dal momento che è stata solo modificata il valore della variabile nnz, cioè la dimensione degli array columnIndex e values.

Solution	SLICE	LUT	FF	DSP	BRAM	CP	CP	CP
						required	achieved	achieved
							post-	post-
							synthesis	implementation
columnIndex, values, x	179	454	450	6	0	10	6.541	6.677
columnIndex	90	267	227	6	0	10	7.489	7.664
values	122	391	232	6	0	10	7.506	7.768
X	143	311	444	6	0	10	6.540	6.790

Table 99: HLS Solution 11 Export RTL Report

6 Conclusions

Solution	RTL	Status Latency		I	Interval			
			\min	avg	max	min	avg	max
1	VHDL	Pass	58	58	58	NA	NA	NA
2	VHDL	Pass	38	38	38	NA	NA	NA
3	VHDL	Pass	58	58	58	NA	NA	NA
4	VHDL	Pass	56	56	56	NA	NA	NA
5	VHDL	Pass	37	37	37	NA	NA	NA
6								
• columnIndex, values, x	VHDL	Pass	37	37	37	NA	NA	NA
• columnIndex	VHDL	Pass	37	37	37	NA	NA	NA
• values	VHDL	Pass	37	37	37	NA	NA	NA
• x	VHDL	Pass	37	37	37	NA	NA	NA
7	VHDL	Pass	38	38	38	NA	NA	NA
8								
• columnIndex, values, x	VHDL	Pass	33	33	33	NA	NA	NA
• columnIndex	VHDL	Pass	37	37	37	NA	NA	NA
• values	VHDL	Pass	37	37	37	NA	NA	NA
• X	VHDL	Pass	33	33	33	NA	NA	NA
9	VHDL	Pass	34	34	34	NA	NA	NA
10								
• columnIndex, values, x	VHDL	Pass	61	61	61	NA	NA	NA
• columnIndex	VHDL	Pass	69	69	69	NA	NA	NA
• values	VHDL	Pass	69	69	69	NA	NA	NA
• x	VHDL	Pass	61	61	61	NA	NA	NA
11								
• columnIndex, values, x	VHDL	Pass	64	64	64	NA	NA	NA
• columnIndex	VHDL	Pass	72	72	72	NA	NA	NA
• values	VHDL	Pass	72	72	72	NA	NA	NA
• x	VHDL	Pass	64	64	64	NA	NA	NA

Table 100: HLS Conclusions C/RTL Cosimulation Report




Figure 9: Latency measurements for different solutions

Solution	SLICE	\mathbf{LUT}	FF	DSP	BRAM	CP	CP	CP
						required	achieved	achieved
							post-	post-
							synthesis	implementation
1	48	93	161	3	0	10	5.745	5.692
2	38	115	139	3	0	10	5.745	5.718
3	48	94	161	3	0	10	5.745	5.692
4	83	186	292	3	0	10	5.745	5.692
5	69	184	196	6	0	10	7.927	7.465
6								
• columnIndex, values, x	113	316	198	6	0	10	7.927	7.799
• columnIndex	84	259	224	6	0	10	7.472	7.843
• values	99	327	224	6	0	10	7.502	8.184
• X	99	250	198	6	0	10	6.541	6.931
7	38	115	139	3	0	10	5.745	5.718
8								
• columnIndex, values, x	123	343	315	6	0	10	6.540	6.571
• columnIndex	85	261	226	6	0	10	7.496	7.654
• values	92	274	196	6	0	10	7.927	7.780
• X	104	248	313	6	0	10	6.540	6.844
9	80	208	263	3	0	10	5.745	5.762
10								
• columnIndex, values, x	204	558	449	6	0	10	6.540	6.840
• columnIndex	83	268	230	6	0	10	7.496	8.115
• values	117	342	199	6	0	10	7.927	7.603
• X	143	311	444	6	0	10	6.540	6.790
11								
• columnIndex, values, x	179	454	450	6	0	10	6.541	6.677
• columnIndex	90	267	227	6	0	10	7.489	7.664
• values	122	391	232	6	0	10	7.506	7.768
• X	143	311	444	6	0	10	6.540	6.790

Table 101: HLS Conclusions Export RTL Report




Figure 10: Utilization Export RTL Plot